

MASARYKOVA UNIVERZITA
FAKULTA INFORMATIKY



Relační přístup k Amazon SimpleDB

DIPLOMOVÁ PRÁCE

Radim Hopp

Brno, 2014

Prohlášení

Prohlašuji, že tato diplomová práce je mým původním autorským dílem, které jsem vypracoval samostatně. Všechny zdroje, prameny a literaturu, které jsem při vypracování používal nebo z nich čerpal, v práci řádně cituji s uvedením úplného odkazu na příslušný zdroj.

Radim Hopp

Vedoucí práce: doc. RNDr. Tomáš Pitner, Ph.D.

Poděkování

Rád bych poděkoval vedoucímu práce panu doc. Pitnerovi za ochotný přístup a věnovaný čas, dále také kolegům Filipovi Nguyenovi a Filipovi Eliášovi za vedení a směřování převážně v implementační části práce.

Shrnutí

Cílem práce je prozkoumání možností relačního přístupu k NoSQL databázi Amazon SimpleDB, konkrétně mapování Teiid SQL dotazů na dotazy databáze Amazon SimpleDB. V rámci práce byl implementován fungující modul do projektu Teiid schopný základních CRUD operací nad databází SimpleDB. Dalším výstupem práce je tutoriál demonstrující instalaci, nastavení a základní použití vytvořeného modulu.

Klíčová slova

Amazon SimpleDB, JBoss Teiid, JBoss, databáze, relační přístup, NoSQL

Obsah

1	Úvod	3
2	JBoss Teiid	4
2.1	<i>Systémy datové federace</i>	4
2.1.1	<i>Systémy datové federace v praxi</i>	5
2.2	<i>Části projektu JBoss Teiid</i>	5
3	Amazon SimpleDB	8
3.1	<i>Struktura databáze SimpleDB</i>	8
3.2	<i>Vlastnosti databáze Amazon SimpleDB</i>	9
3.2.1	<i>SimpleDB jako služba</i>	9
3.2.2	<i>Flexibilita</i>	9
3.2.3	<i>Indexování</i>	9
3.2.4	<i>Konzistence</i>	10
3.2.5	<i>Omezení databáze SimpleDB</i>	11
4	Komunikace s databází Amazon SimpleDB	12
4.1	<i>Přehled příkazů SimpleDB</i>	12
4.2	<i>Podmíněné vkládání a mazání dat</i>	12
4.3	<i>Bezpečnost</i>	13
4.3.1	<i>Proces autentizace</i>	13
4.4	<i>Knihovny pro komunikaci</i>	14
5	Mapování Teiid dotazů na SimpleDB dotazy	15
5.1	<i>Vícehodnotové atributy</i>	15
5.2	<i>SELECT</i>	15
5.3	<i>INSERT</i>	16
5.4	<i>UPDATE</i>	17
5.5	<i>DELETE</i>	17
6	Implementace	18
6.1	<i>Konektor</i>	18
6.1.1	<i>Modul simpledb-api</i>	18
6.1.2	<i>Modul connector-simpledb</i>	19
6.2	<i>Překladač</i>	20
6.2.1	<i>SimpleDBExecutionFactory</i>	21
6.2.2	<i>Executory</i>	24
6.2.3	<i>Visitory</i>	25
6.3	<i>Sestavení</i>	30
6.3.1	<i>Konfigurace jednotlivých SimpleDB modulů</i>	31

6.3.2	Nastavení zásuvného modulu maven assembly plugin	31
7	Quickstart	34
8	Závěr	37
A	Tutoriál	40
B	Obsah přiloženého CD disku	47

1 Úvod

Opensource projekt JBoss Teiid je silným nástrojem pro usnadnění a zkvalitnění práce aplikací nad více heterogenními zdroji dat. Aplikacím poskytuje jednotné rozhraní pro práci s daty a zajišťuje komunikaci s jednotlivými zdroji dat.

Teiid již umí komunikovat s nejčastěji používanými zdroji dat, jakými jsou například relační databáze, LDAP či data uložena v souborech na disku. Bohužel ale nebyl prozatím vytvořen žádný modul Teiidu pro komunikaci s NoSQL databází Amazon SimpleDB ikdyž po takovémto modulu byla poptávka už v roce 2010¹.

Jedním z důvodů, proč tento modul ještě nebyl vytvořen může být jeho netriviálnost. Jelikož je SimpleDB takzvanou NoSQL databází, což znamená, že nevychází z klasického modelu tabulek a relací mezi nimi, a jelikož Teiid ze své přirozenosti přistupuje k datům relačně, vyvstává zde několik možných problémů, které se tato práce snaží řešit.

Nejprve práce uvede čitatele do problému seznámením s projekty JBoss Teiid a Amazon SimpleDB, jejich fungováním, strukturou a fungováním.

Stěžejí částí teoretické práce je prezentace způsobu mapování Teiid SQL dotazů na dotazy a příkazy databáze Amazon SimpleDB. V této sekci nalezne čtenář řešení například absence schopnosti databáze SimpleDB spojit dvě tabulky (v SQL jde o klauzuli JOIN).

Praktická část práce detailně popisuje konkrétní implementaci modulů pro připojení a komunikaci s databází SimpleDB.

Součástí práce je také tutoriál, který čtenáře provede instalací Teiidu, jeho základním nastavením pro použití s implementovaným modulem, připojením k databázi SimpleDB a provedením základních i komplikovanějších dotazů proti databázi pomocí Teiidu nad vzorovými daty. V textu práce je popsána struktura vzorových dat a zdůvodněna jejich volba.

1. V systému JIRA projektu Teiid byl vytvořen požadavek už v dubnu 2010 – <https://issues.jboss.org/browse/TEIID-1070>

2 JBoss Teiid

JBoss Teiid je otevřený software pro virtualizaci dat z více zdrojů. Tento projekt je zaštiťován v rámci JBoss komunitních projektů¹ spolu s projekty jako WildFly nebo GateIn².

Firma Red Hat nabízí také plně podporovanou a certifikovanou verzi pod názvem Red Hat JBoss Data Virtualization (dříve nazývaný Red Hat JBoss Enterprise Data Services Platform). Tento produkt kromě mírně upraveného komunitního projektu Teiid v sobě obsahuje také JBoss Enterprise Application Platform (aplikační server založený na komunitním projektu WildFly) a další produkty³

2.1 Systémy datové federace

Datová federace úzce souvisí s datovou virtualizací (resp. je její specializací).

Datová virtualizace je pojem popisující jakýkoliv přístup k řízení dat, který umožňuje aplikaci získávat a manipulovat s daty bez znalosti technických detailů, jako třeba jak jsou formátována či kde jsou fyzicky uložena. [10, volně přeloženo]

Takto definovaná virtualizace dat neříká nic o dílčích databázích či systémech, pouze říká, že existuje abstraktní vrstva, která zastihuje strukturu, implementaci nebo třeba jazyk komunikace s databází. Takovouto vrstvou může být například aplikace komunikující s databází a vnějšku poskytující REST rozhraní.

Datová federace poskytuje přístup k více heterogenním **autonomním** zdrojům dat. To znamená, že jednotlivým zdrojům dat je v nějaké míře zajištěna samostatnost (což v případě obecné virtualizace dat nemusela být pravda). Je to tedy forma virtualizace dat (je to její specializací).

1. <http://www.jboss.org/overview/>

2. kompletní seznam projektů na <http://www.jboss.org/projects>

3. kompletní seznam produktů a projektů obsažených v Red Hat JBoss Data Virtualization i s použitými verzemi k naleznutí na <https://access.redhat.com/site/articles/703673>

Software zajišťující manipulaci s dílčími databázovými systémy v rámci datové federace se nazývá **systém datové federace** (FDBMS - Federated database management system)[3]. Tento software by měl splňovat několik základních požadavků:

- **Virtualizace dat**
Jelikož je datová federace specializací datové virtualizace, měl by také software pro datovou federaci odstiňovat aplikace k němu přistupující od implementačních, strukturních či jiných detailů jednotlivých databází a databázových systémů.
- **Samostatnost dílčích systémů**
Oproti „čisté“ virtualizaci zaručuje systém datové federace jednotlivým databázovým systémům a zdrojům dat jistou autonomii. To znamená, že k jednotlivým podsystémům by se mělo dát přistupovat také samostatně, bez využití systému datové federace.
- **Schopnost pracovat s heterogenními systémy**
Vedle autonomie jednotlivých subsystémů je dalším hlavním úkolem systémů datové federace schopnost komunikovat a pracovat s heterogenními systémy. Jednotlivé systému můžou být například soubory na disku, data přístupná z REST rozhraní či třeba SQL databáze. Je patrné, že ke každému z těchto datových systémů je nutné přistupovat různě. Zodpovědnost za správnou interpretaci dat nezávisle na schéma, implementaci, či rozdíly v datových typech jednotlivých systémů tak leží na bedrech systému datové federace.

2.1.1 Systémy datové federace v praxi

2.2 Části projektu JBoss Teiid

- **Query engine**
Jedná se o srdce projektu, které zpracovává relační, XML, XQuery a jiné dotazy ze zdrojů dat. Také zajišťuje podporu pro schémata vytvořené z jednoho, či z více různých zdrojů dat. V neposlední řadě se query engine stará o transakce a uživatelem definované funkce.

- **JDBC ovladač**

JDBC ovladač slouží pro jednoduché použití Teiidu v externích java aplikacích.

- **Server**

Tato část je zodpovědná za běh query engine v rámci aplikačního serveru (WildFly nebo Red Hat JBoss Enterprise Application Platform) a zaručuje škálovatelnost a snadnou správu. Součástí je administrační konzole, ve které je možno jednoduše nastavit například nasazenou virtuální databázi nebo nastavení vláken query engine.

- **Konektory a překladače**

Teiid přichází se sadou konektorů a překladačů (connectors & translators), díky kterým je schopen napojit se na řadu různých zdrojů dat. Konektory zajišťují napojení na zdroj dat, překladače potom obstarávají získávání dat podle Teiid požadavků. Základním kamenem jsou konektory pro většinu relačních databází, webové služby, textových souborů a LDAP⁴.

Cíl této diplomové práce je rozšířit tuto sekci o konektor pro NoSQL databázi Amazon SimpleDB.

- **Nástroje**

- Teiid Designer

Teiid Designer je samostatný projekt (není součástí projektu JBoss Teiid), který ovšem také patří mezi komunitní projekty jboss.org. Jedná se o sadu zásuvných modulů pro vývojové prostředí Eclipse, které mimo jiné usnadní vývoj virtuálních databází (pohledy, procedury, ...)

- Nástroje pro monitorování a správu

Dvěmi hlavními nástroji pro monitorování a správu jsou Teiid Web Console (v zásadě jde o rozšíření webové konzole aplikačního serveru o položky pro správu a monitorování

4. Lightweight Directory Access Protocol)

Teiid instance) a zásuvný modul pro RHQ⁵ pro kontrolu více serverů či clusterů Teiidu.

- Skriptování

V rámci Teiidu je také distribuován Teiid AdminShell, což je skriptovací nástroj založený na jazyku Groovy. AdminShell umožňuje spravovat Teiid z příkazové řádky či pomocí skriptu, což uživateli velmi usnadní provádění často se opakujících činností.

5. RHQ je komunitní projekt vedený pod jboss.org pro správu více serverů, <http://www.jboss.org/rhq>

3 Amazon SimpleDB

SimpleDB je databáze z dílen firmy Amazon a patří do skupiny produktů Amazon Web Services. Tato databáze je takzvaná NoSQL, což znamená, že data v ní jsou uložena ve formátu, jaký není běžný pro relační databáze (tabulky, sloupce, řádky) a nepodporuje relace. SimpleDB je poskytována firmou Amazon jako služba a tudíž není možné nasadit databázi SimpleDB na vlastním serveru, ale běží pouze na serverech firmy Amazon.

3.1 Struktura databáze SimpleDB

Strukturu SimpleDB databází je možno přirovnat k tabulkovému procesoru.

- **Uživatelský účet (Customer Account)**

V rámci jednoho účtu lze mít více domén stejně jako v rámci jednoho souboru tabulkového procesoru je možno mít více listů s tabulkami.

- **Doména (Domain)**

Analogie k jedné tabulce v tabulkovém procesoru. Obsahuje řádky (položky), sloupce (atributy) a jednotlivé buňky (hodnoty).

- **Položky (Items)**

Řádky tabulky. Reprezentují jednotlivé objekty uložené v databázi s jedním, či více vyplněnými atributy.

- **Atributy (Attributes)**

Sloupce tabulky. Určují kategorie dat, jakých můžou položky nabývat.

- **Hodnoty (Values)**

Hodnoty si lze představit jako jednotlivé buňky tabulky. Tady se ovšem analogie s tabulkovým procesorem rozchází, neboť jedna „buňka“ může nabývat více hodnot najednou.

Navíc má každý prvek domény (řádek tabulky) povinný atribut `ItemName`, který musí být v dané doméně unikátní.

SimpleDB nepoužívá žádné jiné datové typy kromě typu `String`, takže i čísla jsou v databázi uloženy a je s nimi nakládáno jako s textovými řetězci. To s sebou nese řadu problémů a hlavně zátěž na vývojáře aplikace tyto problémy řešit. Typickým příkladem takového problému je, že čísla nejdou řadit lexikograficky (lexikograficky: $10 < 2$, což je špatně). Řešením je doplnění nul před čísla ($00010 > 00002$, což je správně).

3.2 Vlastnosti databáze Amazon SimpleDB

3.2.1 SimpleDB jako služba

Databáze Amazon SimpleDB je dodávaná jako služba. To znamená, že Amazon neposkytuje možnost nasadit tuto databázi ve vlastním prostředí, ale provozuje ji pouze na svých serverech. Uživatel databáze se tedy nemusí starat o nastavování ani o hardware, ale například ani o škálování, nebo o replikaci dat, jelikož Amazon automaticky distribuuje a synchronizuje data v několika datových centrech umístěných v různých geografických zónách, čímž omezuje nejen riziko ztráty dat, ale také zvyšuje rychlost přístupu k datům v různých místech na světě. Tím pádem se může uživatel databáze plně zaměřit na práci s vlastními daty.

3.2.2 Flexibilita

Flexibilita je další z výhod databáze Amazon SimpleDB. Jelikož je to NoSQL databáze, není potřeba mít pevně dané schéma, jak tomu bývá u SQL databází, ale nové atributy a entity mohou být přidávány takzvaně za pochodu.

3.2.3 Indexování

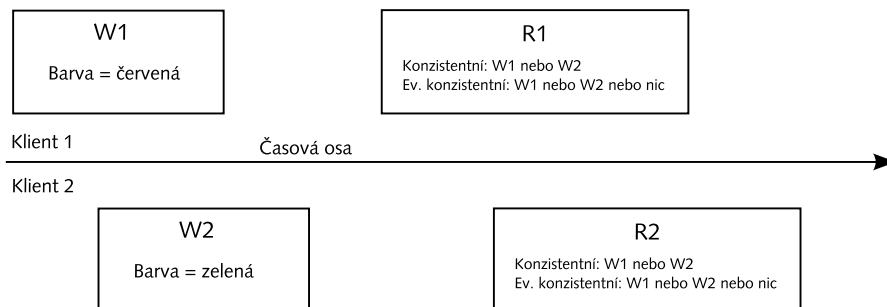
SimpleDB automaticky indexuje veškerá data v ní uložená, čímž tato povinnost odpadá z beder vývojářů aplikace a zvyšuje rychlost navracení výsledků čtecích operací.

3.2.4 Konzistence

Amazon pro zápis zaručuje konzistenci takovou, že úspěšně provedený zápis (použitím příkazů jako např. *PutAttributes*, *BatchPutAttributes*, *CreateDomain*, ...) znamená, že všechny kopie databáze byly změněny. Toto pojetí konzistence ovšem nezaručuje chování při překrytí dvou či více zápisů najednou. Pouze zaručuje, že výsledné data budou na všech kopiích databáze rovná hodnotě jednoho z těchto zápisů (toho, který databáze obdržela nejpozději). Toto bude níže ilustrováno na příkladě. Při čtení si uživatel může zvolit mezi konzistentním a eventuálně konzistentním čtením. Konzistentní čtení zaručuje, že vrátí hodnotu po provedení posledního dosud přijatého zápisu. Eventuálně konzistentní čtení na druhou stranu vrátí hodnotu, která je aktuálně uložena na dotazovaném serveru (tj. může vrátit již neplatnou hodnotu).

Příklad konzistence

Na obrázku 3.1 je uveden příklad, kdy se překrývají dva zápisy. V této situaci není možné určit, jestli po provedení obou zápisů bude výsledná hodnota atributu **Barva** rovna **červená**, nebo **zelená** z toho důvodu, že není zaručeno, kterou instrukci zpracuje SimpleDB jako první. Například kvůli vysoké latenci sítě prvního klienta bude nejprve přijata a zpracována instrukce **W2** druhého klienta a následně přepsána instrukcí **W1**, tedy veškeré následné konzistentní čtení vrátí **Barva=červená**.



Obrázek 3.1: Ilustrace chování databáze SimpleDB

Jak bylo ukázáno, konzistentní čtení v tomto případě mohlo vrátit

jak výsledek **W1**, tak výsledek **W2**. Oproti tomu, výsledek eventuálně konzistentního čtení může být kromě **W1** či **W2** také **nic**. Pravděpodobnost prázdného výsledku se s časem minimalizuje, neboli čím déle po zápisu je čteno, tím větší je pravděpodobnost korektního výsledku.

Základní rozdíl mezi konzistentním a eventuálně konzistentním čtením lze shrnout do tabulky 3.1

Eventuálně konzistentní čtení	Konzistentní čtení
Možné nekorektní výsledky	Vždy korektní výsledek
Rychlejší odezva	Možná pomalejší odezva
Větší datová propustnost	Možná menší datová propustnost

Tabulka 3.1: Tabulka vlastností konzistentního a ev. konzistentního čtení

3.2.5 Omezení databáze SimpleDB

Kromě výše zmíněného chování, které by se v jistých situacích dalo považovat za omezení, je asi největším omezením velikost domény, jak co se místa na disku týče, tak také maximální počet atributů. Konkrétně je horní hranice 10 GB pro data a 1 miliarda atributů na jednu doménu. Domén je možno vytvořit až 250 na jeden uživatelský účet.

4 Komunikace s databází Amazon SimpleDB

4.1 Přehled příkazů SimpleDB

- **CreateDomain** slouží k vytvoření nové domény.
- **DeleteDomain** vymaže danou doménu.
- **ListDomains** vrátí seznam domén asociovaných s daným uživatelským účtem.
- **DomainMetadata** slouží k získání informací o doméně (datum vytvoření, počet položek v doméně, počet atributů, ...)
- **PutAttributes** vloží novou položku s danými hodnotami atributů, či upraví již stávající položku.
- **Select** se podobá běžnému **SELECT** příkazu, který je dobře známý z SQL jazyků. Je ovšem mírně omezen a to například absencí **JOIN** klauzule. Přesný přehled možností příkazu **SELECT** databáze SimpleDB je uveden v dokumentaci¹
- **GetAttributes** vrátí hodnoty požadovaných atributů jedné dané položky. Umožňuje specifikovat jeden, či více požadovaných atributů, nebo také všechny atributy dané položky.

4.2 Podmíněné vkládání a mazání dat

SimpleDB v aktuální verzi (od 24. února 2010) podporuje takzvaný podmíněný zápis a mazání dat.

Při tomto podmíněném zápise (mazání) se spolu s běžnými parametry odešle také podmínka a očekávaný výsledek vyhodnocení dané podmínky. Zápis se poté provede pouze tehdy, je-li vyhodnocená podmínka rovna očekávanému výsledku.

Tato vlastnost se dá použít například pro implementaci čítače (přečte aktuální stav čítače a pokusí se zapsat nový stav čítače za podmínky, že

1. <http://awsdocs.s3.amazonaws.com/SDB/latest/sdb-dg.pdf>

stav čítače byl nezměněn), což by bez podmíněného vložení byl netriviální úkol. Také se tímto rozšiřují možnosti kontroly konkurenčního přístupu k datům (pomocí optimistických protokolů „optimistic concurrency control“).

4.3 Bezpečnost

Pro autentizaci má každý uživatel „ID přístupového klíče“ (20 alfanumerických znaků) a „tajný přístupový klíč“ (40 alfanumerických znaků), kterými podepisuje každý požadavek vůči SimpleDB. Sama Amazon SimpleDB nemá nástroj pro autorizaci, ten je ovšem integrován do správy identit a přístupu AWS (AWS Identity and Access Management - systém pro správu uživatelů a jejich práv v rámci celého AWS), takže je možné omezit práva jednotlivým uživatelům. Jediným problémem může být skutečnost, že nelze definovat přístupové práva pro jiný AWS účet – pro každého uživatele domény musí být vytvořen uživatel v rámci AWS účtu vlastního domény.

4.3.1 Proces autentizace

1. Vytvoření řetězce dotazu
2. Kanonizování řetězce dotazu (seřazení parametrů, zakódování parametrů a jejich hodnot URL kódováním²), ...)
3. Vypočítání HMAC³ z kanonizovaného textového řetězce za použití „tajného přístupového klíče“ jako klíče a SHA256 nebo SHA1 jako hashovacího algoritmu. Tento podpis se připojí k původnímu požadavku jako parametr `signature` spolu s ID přístupového klíče jako `AWSAccessKeyId`.

Zde je ukázán proces autentizace pouze zjednodušeně. Přesný návod jak sestavit validní požadavek je dostupný v dokumentaci SimpleDB.

2. Podle RFC 3986, kapitola 2 – <http://tools.ietf.org/html/rfc3986>

3. Podle RFC 2104 – <http://www.ietf.org/rfc/rfc2104.txt>

4.4 Knihovny pro komunikaci

Amazon poskytuje knihovny pro komunikaci se SimpleDB (a ostatními AWS službami) v několika jazycích (Java, PHP, Python, Ruby a .NET). Knihovna pro jazyk Java, která byla v této práci použita, nejenže poskytuje model pro práci s doménami, atributy a podobně, ale také významně usnadňuje autentizační proces (není nutné „ručně“ počítat podpis).

5 Mapování Teiid dotazů na SimpleDB dotazy

V této kapitole bude obecně ukázáno, jakým způsobem byly mapovány Teiid dotazy na dotazy databáze SimpleDB. Konkrétně se jedná o příkazy `SELECT`, `INSERT`, `UPDATE` a `DELETE`.

5.1 Vícehodnotové atributy

Teiid přistupuje k datům jako běžná relační databáze, tedy jednomu řádku a sloupci odpovídá nejvýše jedna hodnota. Z tohoto důvodu je nutné ošetřit přístup k vícehodnotovým atributům. Nabízí se několik řešení:

1. Byl-li by dopředu znám maximální počet hodnot u jednotlivých atributů, mohl by Teiid vnímat vícehodnotové atributy jako více sloupců tabulky (pro každou z možných hodnot jeden sloupec). Tímto přístupem by se ovšem zafixovalo schéma a přišli bychom o jednu z hlavních výhod databáze SimpleDB (SimpleDB netrvá na pevném schématu).
2. Zakódovat všechny hodnoty vícehodnotového atributu do jediného textového řetězce, který by byl lidsky i strojově čitelný. Tímto odpadá problém se změnou počtu hodnot atributu.

Ve finální implementaci byl zvolen druhý přístup a hlouběji bude probrán v kapitole 6.

5.2 SELECT

Jelikož SimpleDB podporuje mírně omezený `SELECT`, stačí vždy pouze upravit řetězec příkazu `SELECT` generovaný Teiidem, aby byl srozumitelný pro SimpleDB. Naštěstí lze pro každý překladač nadefinovat sadu podporovaných vlastností. Nepodporované vlastnosti obslouží sám Query Engine (např. překladač nepodporuje `JOIN` klauzuli. Query Engine tedy rozloží dotaz s `JOIN` klauzulí na dva jednoduché dotazy, ty poté předá překladači a výsledné data zpracuje programově v paměti).

Struktura příkazu `SELECT` databáze SimpleDB:

```
select output_list  
from domain_name  
where [expression]  
[sort_instructions]  
limit [limit]
```

Ze struktury je zřejmé, že žádné velké změny nebude třeba provádět. Je nutné definovat, že překladač nepodporuje `JOIN` klauzuli a poté zajistit, aby byly korektně prováděny jednoduché SQL dotazy na které byl původní dotaz rozložen. Zde vyvstává pár problémů:

1. Dotazu obsahujícímu atribut `itemName()` (povinný unikátní atribut, který má každá položka) musí být tento atribut odebrán – tento atribut je automaticky vracen v odpovědi databáze ikdyž není specifikován. Naopak pokud je požadován spolu s jinými atributy, databáze vrátí chybu. Toto platí s výjimkou dotazu, kdy je `itemName()` jediným požadovaným atributem.

Tento dotaz je korektním dotazem na databázi SimpleDB a vrátí hodnoty atributu `itemName()` všech položek v doméně `TestDomain`:

```
SELECT itemName() FROM TestDomain
```

Tento dotaz vrátí chybovou hlášku `InvalidQueryExpression`:

```
SELECT itemName(), attribute1 FROM TestDomain
```

2. Další problém může vyvstat ve `WHERE` části výrazu. Těmto potížím se dá vyhnout správným nastavením schopností překladače.

5.3 INSERT

Zde je situace stále celkem jednoduchá, neboť `INSERT` vždy vkládá jeden nový řádek, což je téměř ekvivalentní příkazu `PutAttributes`. Je zde akorát potřeba získat z Teiid příkazu `INSERT` seznam sloupců, jejich hodnot a název domény do které má proběhnout vložení. Vzhledem ke zvolenému řešení problému vícehodnotových atributů není nutné se jimi zabírat zde (logika obsluhy vícehodnotových atributů je v implementaci extrahována do samostatného modulu).

5.4 UPDATE

U UPDATE je situace poněkud složitější, neboť je možné měnit více položek najednou (díky WHERE klauzuli) a příkazy `PutAttributes` a `BatchPutAttributes` neumožňují měnit více položek specifikovaných pomocí kritéria najednou. Je tedy nutné nejprve pomocí `SELECT` příkazu nad požadovanou doménou a kritérii z Teiid UPDATE dotazu získat jména všech upravovaných položek (atribut `itemName()`). Teprve poté lze pomocí několika `PutAttributes`, či jediného `BatchPutAttributes` dané položky upravit.

5.5 DELETE

Podobně jako u příkazu UPDATE je nejprve potřeba získat jména všech položek, které mají být smazány a ty následně pomocí `DeleteAttributes` smazat z databáze.

6 Implementace

V této kapitole bude rozebrána konkrétní implementace, problémy, které se během implementace vyskytly, a jejich řešení.

6.1 Konektor

Základním kamenem a prvním krokem v implementaci bylo vytvoření konektoru.

Java EE Connector Architecture (JCA) je standardizované řešení pro připojení k podnikovým informačním systémům (enterprise information systems). Stejně jako je JDBC zodpovědné pro připojení Java EE aplikací k databázím, JCA je obecnější architektura pro připojení k systémům, pro které není vytvořen JDBC ovladač. Základem každého konektoru je tzv. resource adapter, jež je odpovědný za přístup a interakci s daným informačním systémem, který cheme připojit. Jednotlivé Java EE aplikace, nasazené v aplikačním serveru, poté tento resource adapter využívají pro komunikaci.

Specifikace JCA je vyvíjena v rámci Java Community Process pod číslem JSR 322¹

6.1.1 Modul `simplifiedb-api`

Tento modul reprezentuje API pro komunikaci s databází SimpleDB a jako samostatný modul vzniknul hlavně kvůli oddělení závislostí na java knihovnu pro komunikaci se SimpleDB (`aws-java-sdk`) od ostatních modulů.

Modul obsahuje pouze jedinou java třídu a jedno rozhraní a to `SimpleDBAPIClas` a `SimpleDBConnection`.

- `SimpleDBConnection` je rozhraní rozšiřující rozhraní `Connection` z balíčku `javax.resource.cci` (`Connection` reprezentuje připojení na externí zdroj na aplikační vrstvě – díky třídám implementující toto rozhraní je možné přistupovat k požadovaným zdrojům).

1. Dostupné na webu Java Community Process – <http://www.jcp.org>

- `SimpleDBAPIClass` je třída zaobalující potřebné příkazy databáze SimpleDB. Za povšimnutí stojí hlavně metoda `Set<String> getAttributeNames(String domainName)`, která vrací jména všech atributů v doméně, ovšem jediný způsob jak toho docílit je provedení příkazu `SELECT * FROM <domainName>` a z odpovědi získat jména všech atributů (nestačí dotázat se například na jednu položku, neboť kdyby daná položka neměla vyplněný nějaký atribut, tento atribut by v odpovědi nebyl obsažen).

Také je v této třídě obsažena veškerá logika manipulace s vícehodnotovými atributy.

6.1.2 Modul `connector-simpliedb`

Jedná se o plnohodnotný, ikdyž poměrně jednoduchý, Java EE konektor pro SimpleDB. Konektory jsou běžně baleny jako RAR (Resource Adapter Archive), které lze poté nasadit na aplikační server pouhým nakopírováním do složky `deploy` serveru. Teiid poskytuje základní implementaci rozhraní potřebných pro vytvoření základního konektoru. Zde bylo důležité uzpůsobit tuto základní implementaci potřebám databáze SimpleDB.

- Třída `SimpleDBManagedConnectionFactory` rozšiřuje abstraktní třídu `BasicManagedConnectionFactory` (základní Teiid implementace). V této třídě je nutno definovat proměnné, které jsou potřebné pro připojení ke zdroji – tedy proměnné ve kterých bude uložen ID přístupového klíče a tajný přístupový klíč spolu s metodami pro jejich nastavení a získání (get a set metody). Požadované hodnoty budou aplikačním serverem získány z konfiguračního souboru serveru (typicky třeba `standalone.xml`) a vloženy pomocí `set` metod do těchto proměnných. Další důležitou částí je implementace abstraktní metody `createConnectionFactory()`, pomocí které je vytvořena instance `ConnectionFactory`. Ta slouží ke generování jednotlivých připojení ke zdroji dat (SimpleDB).
- Jako implementace rozhraní `Connection` zde slouží třída `SimpleDBConnectionImpl`. Ta kromě implementování rozhraní `Connection` rozšiřuje základní Teiid implementaci `BasicConnection`. Nám zde tedy stačí zajistit přístup k instanci třídy `SimpleDBAPIClass`. To

je splněno instanciováním v konstruktoru a přiřazením do privátní proměnné, která je poté dostupná pomocí její `get` metody.

S takto připraveným připojením lze poté v samotném překladači snadno volat metody definované v `SimpleDBAPIClass` např. takto:

```
((SimpleDBConnectionImpl)connection).getAPIClass()
    .getDomains();
```

- Dalším krokem je vytvoření konfiguračních souborů `MANIFEST.MF` a `ra.xml`. Oba soubory je nutno umístit do složky `META-INF`.

`MANIFEST.MF` obsahuje pouze závislosti resource adapteru. V případě našeho konkrétního adapteru je to:

```
Dependencies: org.jboss.teiid.common-core,
              org.jboss.teiid.api, javax.api,
              org.jboss.teiid.translator.simplesdb.api
```

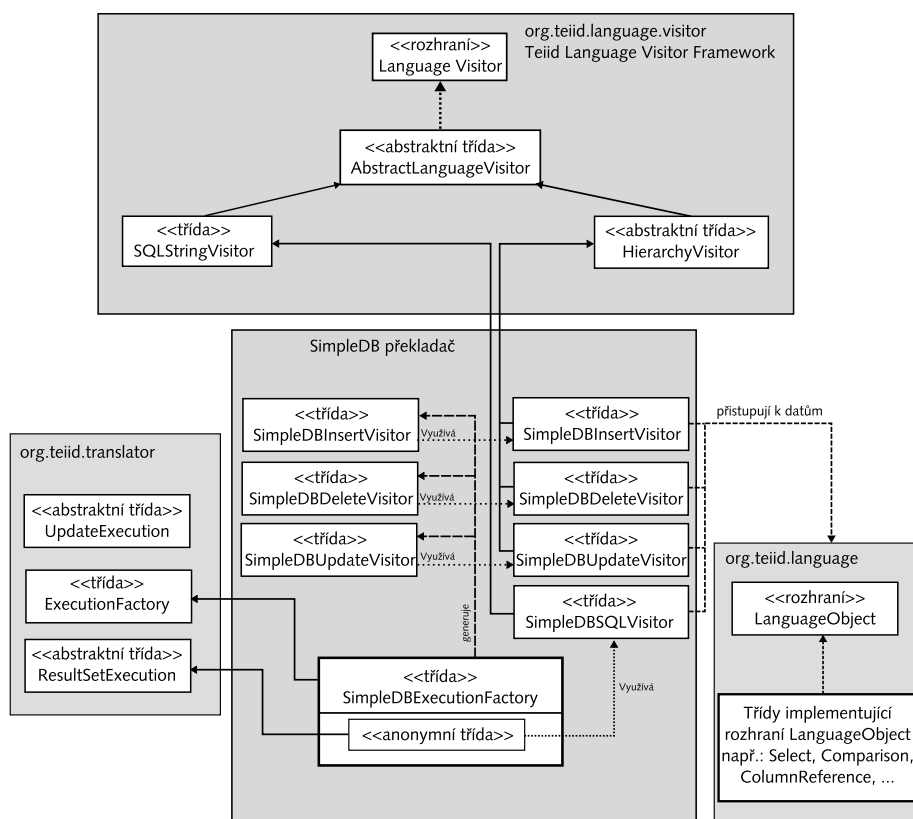
V deployment descriptoru `ra.xml` definujeme hlavní třídu resource adapteru (tj. třída implementující rozhraní `Resource Adapter`), třídu implementující rozhraní `ManagedConnectionFactory` a definujeme proměnné potřebné k připojení k SimpleDB (ID přístupového klíče a tajný klíč).

- Celý tento modul je poté běžně zkompileován a balen jako Resource Adapter Archive – RAR (běžný Java archive – JAR s příponou `.rar`), který může být nasazen na aplikační server zkopírováním do složky `deploy/`. Jelikož se zde ale nejedná o konektor třetí strany, ale o konektor, který bude dodáván s projektem Teiid jako jeden ze základních konektorů, nestačí zajistit, že bude sestaven jako RAR, ale je potřeba, aby ve výsledku byl zařazen mezi moduly aplikačního serveru. K tomu potřebné kroky budou popsány níže v kapitole 6.3.1 zabývající se kompilováním a sestavováním projektu pomocí projektu Apache Maven.

6.2 Překladač

Tento modul je rozdělen na tři logicky oddělené části. V první je pouze třída `SimpleDBExecutionFactory`, která je základní třídou překladače. V další části jsou zde takzvané executory – třídy zajišťující vykonávání

jednotlivých příkazů. Jako poslední jsou takzvané visitory – třídy, které prochází strukturu Teiid SQL příkazu a získávají data, jež jsou poté použita v executorech. Každá z těchto částí je v samostatném java balíčku.



Obrázek 6.1: Struktura překladače SimpleDB

6.2.1 SimpleDBExecutionFactory

Základním kamenem SimpleDB překladače je třída `SimpleDBExecutionFactory` rozšiřující abstraktní třídu `ExecutionFactory<F,C>`, kde `F` je factory třída konektoru a `C` je třída připojení – v našem případě se jedná o `ConnectionFactory` a `SimpleDBConnection`.

Nejprve v této třídě najdeme metody definující schopnosti překladače. Jedná se o metody s prefixem `supports` vracející boolean hodnotu podle

toho zda překladač danou schopnost podporuje, či ne. Pro překladač SimpleDB byla zvolena tato množina podporovaných funkcí:

```
supportsCompareCriteriaEquals
supportsCompareCriteriaOrdered
supportsInCriteria
supportsIsNullCriteria
supportsRowLimit
supportsNotCriteria
supportsOrCriteria
supportsLikeCriteria
```

Zbylé funkce obstarává logika Teiidu.

Dále tato třída obsahuje metodu `void getMetadata(MetadataFactory metadataFactory, SimpleDBConnection conn)` (ukázaná na obrázku 6.2.1), kterou Teiid volá při inicializaci pro každou uživatelem definovanou virtuální databázi. Úkolem této metody je načíst strukturu databáze (tabulky, sloupce, typy, ...) a pomocí `metadataFactory` ji předat Teiidu. Toho je docíleno iterací přes všechny domény a na nich voláním metody `getAttributeNames()` (metoda třídy `SimpleDBAPIClass` k jejíž instanci lze přistupovat přes třídu implementující připojení – `SimpleDBConnection`). Je nutné nastavit všem sloupcům datový typ `String` a také nezapomenout na atribut `itemName()`. Takto získané data poté stačí uložit do instance třídy `MetadataFactory`.

Poslední dvě implementované metody v této třídě jsou metody `createResultSetExecution` a `createUpdateExecution`, kde obě mají ve vstupních parametrech příkaz (`SELECT`, `UPDATE`, ...), kontext, metadata a připojení. Obě tyto metody vrací instanci třídy implementující rozhraní `Execution`. Z tohoto rozhraní je pro implementaci SimpleDB překladače nejdůležitější metoda `void execute()`, jejíž implementace je odpovědná za provádění konkrétního příkazu.

- `createResultSetExecution`

Tato metoda je zodpovědná za veškeré příkazy určené k získávání dat – tedy primárně příkaz `SELECT`. Metoda `createResultSetExecution` vrací nově vytvořenou anonymní třídu s implementovanými metodami `void execute()` a `List<?> next()`. Metoda `execute` pouze pomocí třídy `SimpleDBSQLVisitor` získá seznam sloupců, poté pomocí stejné třídy získá textový řetězec odpovídající příkazu `SELECT` a nad těmito daty zavolá metodu `performSelect`

```

1 public void getMetadata(MetadataFactory metadataFactory,
2                         SimpleDBConnection conn){
3     List<String> domains = conn.getAPIClass().getDomains();
4     for (String domain : domains) {
5         Table table = metadataFactory.addTable(domain);
6         table.setSupportsUpdate(true);
7         Column itemName = new Column();
8         itemName.setName("itemName()");
9         itemName.setUpdatable(true);
10        itemName.setNullType(NullType.No_Nulls);
11        Map<String, Datatype> datatypes = metadataFactory
12                                           .getDataTypes();
13        itemName.setDatatype(datatypes.get("String"));
14        table.addColumn(itemName);
15        for (String attrName : conn.getAPIClass()
16                                           .getAttributeNames(domain)) {
17            Column column = new Column();
18            column.setUpdatable(true);
19            column.setName(attrName);
20            column.setNullType(NullType.Nullable);
21            column.setDatatype(datatypes.get("String"));
22            table.addColumn(column);
23        }
24    }
25 }

```

Obrázek 6.2: Ukázka metody getMetadata

API třídy, která získá data z databáze a vrátí je jako seznam. Ten je uložen do interní proměnné a v metodě `next()` jsou tyto data pomocí iterátoru předávána Teiidu.

- **createUpdateExecution**

Zde se obstarává vykonávání všech metod manipulujících s daty – **INSERT**, **UPDATE**, **DELETE** a **BatchedUpdate** (který ovšem překladač `simpledb` nepodporuje).

Opět, podobně jako u `createResultSetExecution` je zde potřeba vrátit třídu implementující rozhraní `UpdateExecution`, které se

od `ResultSetExecution` liší pouze v metodě získávání dat. Místo `List<?> next()` je zde `int[] getUpdateCounts()`.

6.2.2 Executory

Jelikož je v metodě `createUpdateExecution` situace složitější než v metodě `createResultSetExecution` a řešení pomocí anonymní třídy by bylo velmi rozsáhlé, byla zde implementace rozdělena do 3 samostatných tříd podle příkazu, který zpracovávají – `SimpleDBInsertExecute`, `SimpleDBDeleteExecute` a `SimpleDBUpdateExecute`.

Všechny tyto tři třídy využívají visitory (třídy vytvořené podle návrhového vzoru Visitor, budou popsány v kapitole 6.2.3) pro získání relevantních dat ze zadaného příkazu.

- `SimpleDBInsertExecute` je nejjednodušší z trojice executorů. Pouze pomocí `SimpleDBInsertVisitor` získá kolekci dvojic `<jménoAtributu, hodnotaAtributu>`, kde hodnota může být ve formátu `^[.+\]$`, což značí vícehodnotový atribut. Tuto kolekci poté předá metodě `perform Insert()` API třídy. O správné zpracování vícehodnotových atributů se postará tato metoda.
- `SimpleDBUpdateExecute` je opět poměrně jednoduchá třída – mezivrstva mezi visitorem a API třídou vykonávající samotný dotaz na SimpleDB. Pomocí visitoru zjistí, které položky odpovídají porovnání v dotazu. Přesněji řečeno získá hodnotu atributu `itemName()` všech položek odpovídajících podmínce `WHERE`. Dále zkonstruuje mapu `Map<String, Map<String, String>` – pro každý název položky získá pomocí visitoru `SimpleDBUpdateVisitor` mapu `<jménoAtributu, hodnotaAtributu>` a s touto mapou `map` provede pomocí metody `performUpdate()` API třídy samotné upravení dat v databázi.
- V případě `SimpleDBDeleteExecute` je zde pro jednoduchost a efektivnost rozděleno vykonávání do tří nezávislých větví podle situací, které mohou nastat:
 - Příkaz `DELETE` nemá klauzuli `WHERE`
V tomto případě executor rovnou pomocí API třídy zjistí hodnoty atributu `itemName()` všech položek v dané doméně

- a tyto položky postupně pomocí metody `performDelete()` API třídy vymaže.
- Příkaz `DELETE` má klauzuli `WHERE` ve formátu `itemName() = <hodnota>`
Zde se jedná o jednoduché vymazání jediné položky. Tato položka je pomocí metody `performDelete()` vymazána.
 - Příkaz `DELETE` má klauzuli `WHERE` ve formátu jiném než `itemName() = <hodnota>`
V tomto případě je nutné nejprve zjistit hodnoty atributu `itemName()` položek, jež odpovídají podmínce klauzule `WHERE`. Tato logika je ponechána visitoru a zde se poté jen zavolá na získaných jménech metoda `performDelete()` API třídy.

Všechny tyto executory mají povinnost pamatovat si počet upravených, přidaných, či vymazaných řádků a tuto hodnotu zpřístupnit pomocí metody `int[] getUpdateCounts()`

6.2.3 Visitor

Tato sekce obsahuje 4 visitory. Každý ze 4 příkazů `SELECT`, `UPDATE`, `DELETE`, `INSERT` má jiné požadavky, proto pro každý z nich byl vytvořen samostatný visitor.

Nejprve je ale třeba vysvětlit návrhový vzor `Visitor`, na kterém je celá tato sekce postavená.

Návrhový vzor `Visitor`

Návrhový vzor `visitor` (někdy též návštěvník) je jedním ze základních návrhových vzorů popsaných již roku 1994 v knize *Design Patterns: Elements of Reusable Object-Oriented Software*. Jedná se o návrhový vzor, pomocí kterého je možné přidat skupině tříd dodatečnou funkcionalitu bez nutnosti změnit všechny tyto třídy. Také umožňuje funkcionalitu rozšířit za běhu programu.

V tomto návrhovém vzoru jsou třídy rozdělené do dvou skupin – navštěvované třídy a navštěvující třídy. Navštěvované třídy poskytují pouze základní funkcionalitu a navíc musí implementovat metodu, která přijme návštěvníka a předá mu data nutná k jeho správnému fungování.

Návštěvníci pro každou třídu, které chce rozšířit funkcionalitu, implementuje metodu `visit` se vstupním parametrem navštěvované třídy.

Jazykový visitor v Teiidu

Teiid disponuje rozhraním pro procházení a získávání dat ze stromů objektů jazyka založené na návrhovém vzoru visitor.

Každý Teiid příkaz je reprezentován stromem jazykových objektů – tříd implementujících rozhraní `LanguageObject`. Toto rozhraní definuje jedinou metodu:

```
void acceptVisitor(LanguageObjectVisitor visitor);
```

`LanguageObjectVisitor` je základní rozhraní pro všechny visitory a definuje `visit` metody pro všechny jazykové objekty jako například:

```
public void visit(AggregateFunction obj);
```

Teiid kromě základních rozhraní poskytuje i 3 základní implementace, kterých se dá využít při psaní vlastního visitoru:

- `AbstractLanguageVisitor` je prázdnou implementací rozhraní `LanguageObjectVisitor` poskytující nástroje pro procházení stromu jazykových objektů (sama ale žádné procházení nedělá). Tato třída není určena pro přímé použití, proto je definována jako abstraktní a je určena pouze pro použití jako rodičovská třída k rozšíření.
- `HierarchyVisitor` je podtřídou `AbstractLanguageVisitor` a je oproti její nadtřídě schopna projít všechny uzly stromu jazykových objektů. Nad těmito objekty ovšem neprovádí žádnou akci, pouze poskytuje jakýsi návod jak projít celý strom. Tato třída je také definována jako abstraktní a je určena k rozšiřování.
- `DelegatingHierarchyVisitor` je rozšířením `HierarchyVisitor` o možnost projít strom před a po projití hlavního visitoru. Tento nástroj není v případě SimpleDB nutné využívat, proto se jím nebudeme zabývat dále.
- `SQLStringVisitor` je rozšířením základní abstraktní třídy `AbstractLanguageVisitor`, která dokáže daný objekt Teiid jazyka převést na textový řetězec odpovídající SQL příkazu.

- `CollectorVisitor` je třída vhodná pro získání všech objektů určitého typu z jazykového stromu.

SimpleDBSQLVisitor

`SimpleDBSQLVisitor` není v této práci použit pouze pro příkaz `SELECT`, ale využívají jej i ostatní visitory pro získání jmen položek vyhovující podmínce.

Jelikož má `SimpleDB` příkaz `SELECT` mírně odlišnou strukturu a nějaké omezení, nelze použít Teiidem dodávaný `SQLStringVisitor`, ale byla vytvořena tato třída. `SimpleDBSQLVisitor` je rozšířením třídy `SQLStringVisitor` s přetíženými metodami `visit` pro objekty `Select`, `ColumnReference`, `Limit`, `Like` a `Comparison`.

- `public void visit(Select obj)`
Tato metoda je přetížena kvůli nutnosti odstranit atribut `itemName()` ze seznamu sloupců (`itemName()` je vracen automaticky a není třeba se na něj dotazovat)
- `public void visit(ColumnReference obj)`
Implementace v `SQLStringVisitor` vypisuje sloupec ve formátu `'tabulka'. 'sloupec'`, což pro `SimpleDB` není žádoucí a je potřeba vypisovat sloupec bez tabulky.
- `public void visit(Comparison obj)`
Jelikož Teiid podporuje operátor `NOT` (a v `SimpleDBExecutionFactory` bylo definováno, že náš překladač operátor `NOT` podporuje), zdálo by se, že v této oblasti je vše v pořádku. Není tomu ovšem tak, neboť ve chvíli, kdy překladač podporuje `NOT` operátor, zaručuje také podporu negovaných operátorů. Jedním z těchto negovaných operátorů je operátor „nerovná se – `<>`“, a jelikož jej databáze `SimpleDB` nepodporuje, musí být při generování SQL řetězce převeden na „`NOT =`“

```

1  if (obj.getOperator().equals(Operator.NE)){
2      Comparison c = new Comparison(obj.getLeftExpression(),
3                                     obj.getRightExpression(), Operator.EQ);
4      append(new Not(c));
5  }
```


- Další změny jsou pouze minoritního charakteru.

SimpleDBInsertVisitor

Vše co je potřeba na vykonání SimpleDB příkazu `PutAttributes` je jméno domény a mapa jména atributu a hodnot atributů. To je zajištěno rozšířením abstraktní třídy `HierarchyVisitor` a přetížením jeho `visit` metod pro parametry typu `ColumnReference` a `ExpressionValueSource`.

Při návštěvě `ColumnReference` (sloupců) se tvoří seznam názvů sloupců. Poté se při návštěvě `ExpressionValueSource` (ekvivalent klauzuli `VALUES`) tvoří mapa, kde jako klíč poslouží jméno atributu a jako hodnota hodnota atributu. Jelikož `HierarchyVisitor` prochází pomyslný strom Teiid příkazu do hloubky, je zajištěno, že seznam jmen atributů bude sestaven před začátkem zpracovávání vkládaných hodnot.

Pro získání těchto hodnot je implementována statická metoda `getColumnsValuesMap(Insert insert)`, ta instanciuje vlastní třídu předá ji objektu `Insert` jako návštěvníka, který ji projde. Následně vrátí získané hodnoty.

SimpleDBUpdateVisitor

Ikdyž je i tento visitor založen na `HierarchyVisitor` je zde situace poněkud složitější, než v případě `SimpleDBInsertVisitor` a to hlavně protože pokud v příkazu existuje podmínka, je nutné zjistit jména všech položek odpovídajících podmínce. Proto je zde zvolen jiný přístup, než u `SimpleDBInsertVisitor` (statické třídy pro získávání dat). Zde je navštěvování položek příkazu spuštěno v konstruktoru, tedy při vytvoření instance, a následně lze `get` metodami získat „vydolované“ data.

Konstruktor je parametrický a kromě instance `Update` přijímá i instanci připojení a to z kvůli možné podmínce (je potom potřeba dotázat se databáze na jména položek vyhovující podmínce).

Požadované data zde jsou: název domény, mapa jmen atributů a jejich hodnot a seznam jmen položek odpovídajících podmínce.

Přetížené metody `visit` jsou pro objekty typu `Update`, `SetClause` a `Comparison`

- `Update` kromě implicitního zavolání metod `visit` pro objekty níže ve stromu příkazu (`SetClause`, `Condition`) si také uloží jméno

domény do privátní proměnné.

- `SetClause` vytvoří a naplní mapu jmen atributů a jejich hodnot.
- Hlavním úkolem metody `visit(Comparison obj)` je získání hodnot atributu `itemName()` všech položek vyhovující podmínce. To lze jednoduše zajistit `SELECT` dotazem přímo na databázi `SimpleDB`, kde se do `WHERE` klauzule vloží řetězec vygenerovaný pomocí `SimpleDBSQLVisitor` pro danou podmínku, jak je vidět v následující ukázce kódu na řádcích 4-6. Na řádcích 7-8 pak pouze probíhá uložení získaných jmen položek do privátní proměnné `itemNames`.

```

1 public void visit(Comparison obj) {
2     ArrayList<String> columns = new ArrayList<String>();
3     columns.add("itemName()");
4     List<List<String>> response = apiClass.performSelect("SELECT "
5         +"itemName() FROM "+tableName+" WHERE "+SimpleDBSQLVisitor
6         .getSQLString(obj), columns);
7     for (List<String> list : response) {
8         itemNames.add(list.get(0));
9     }
10 }
```

`SimpleDBDeleteVisitor`

Zde je použit stejný přístup jako u `SimpleDBUpdateVisitor`. Tedy spuštění procházení stromu v parametrickém konstruktoru, který kromě instance navštěvovaného objektu přijímá také API třídu `SimpleDBAPIClass` potřebnou pro komunikaci se `SimpleDB`.

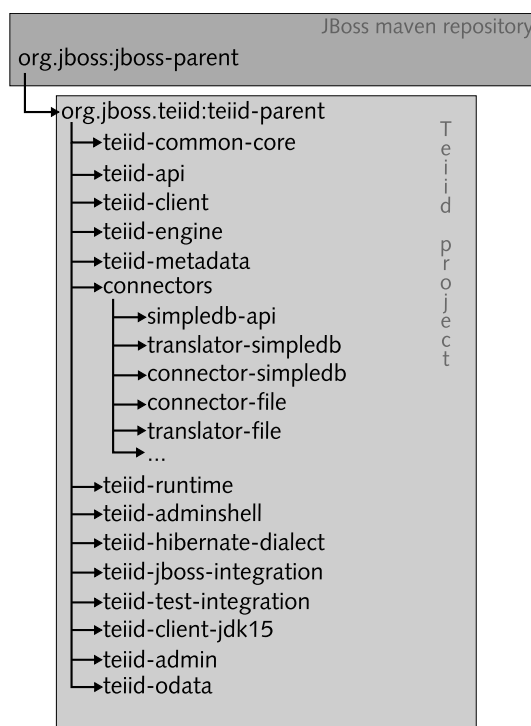
Je zde potřeba rozlišovat mezi třemi základními situacemi:

- Žádná `WHERE` klauzule – tato situace je vyřešena již v executoru `SimpleDBDeleteExecute` dotázáním na existenci této klauzule a případným smazáním všech záznamů z domény.
- V klauzuli `WHERE` je jednoduchá podmínka tvaru `itemName() = <hodnota>` nebo `<hodnota> = itemName()`. V tomto případě je nastavena hodnota privátní proměnné `boolean isSimpleDelete` na `true`. Na tuto proměnnou se poté dotazuje `SimpleDBDeleteExecute` a zařizuje se podle ní.

- Posledním případem je složitější podmínka ve **WHERE** klauzuli. V tomto případě se `SimpleDBDeleteVisitor` chová téměř tožně jako `SimpleDBUpdateVisitor` a to tak, že se nejprve dotáže databáze SimpleDB jednoduchým **SELECT** příkazem s **WHERE** klauzulí daného **DELETE** příkazu (vygenerovanou pomocí `SimpleDBSQLVisitor`).

6.3 Sestavení

Pro kompilaci a sestavení celého projektu je použit projekt Apache Maven. Maven kromě usnadnění a zautomatizování procesu sestavení také obstarává správu závislostí. Schopnosti mavenu je dále možné rozšířit pomocí zásuvných modulů (plug-inů).



Obrázek 6.3: Maven struktura projektu Teiid

Projekt Teiid je rozdělen do takzvaných modulů. Moduly jsou jednotlivé logické celky vytvořené jako java projekty. Každý takový modul

má svůj soubor `pom.xml` (Project Object Model) – konfigurační soubor projektu. V tomto souboru jsou definovány identifikátory projektu (ID artefaktu, ID skupiny, verze, ...), identifikátory rodičovského POM souboru, závislostí a konfigurací použitých maven zásuvných modulů.

6.3.1 Konfigurace jednotlivých SimpleDB modulů

- **simplifiedb-api**

Zde není potřeba žádné speciální konfigurace. Stačí definovat v `pom.xml` závislosti, rodičovské `pom.xml` a v rodičovském `pom.xml` definovat tento projekt jako modul (přidat do tagu `<modules>`).

- **connector-simplifiedb**

Tento modul má na konfiguraci zvláštní požadavky, neboť musí být sestaven jako `rar` archiv a následně nainstalován do lokálního repozitáře, aby pak byl dostupný v poslední fázi sestavení kompletního projektu Teiid.

Potřebné soubory `MANIFEST.MF` a `ra.xml` byly popsány již v kapitole 6.1.2, zbývá tedy nastavit Maven pomocí `pom.xml`. K sestavení projektu jako `rar` je použit zásuvný modul `maven-rar-plugin` spuštěný v rámci maven fáze `install`. Toto vytvoří korektní `rar` archiv a následně (stále ve fázi `install`) je pomocí zásuvného modulu `maven-install-plugin` tento soubor nainstalován do lokálního maven repozitáře, aby byl přístupný i ostatním projektům.

- **translator-simplifiedb**

Překladač nevyžaduje žádné speciální nastavení. Stačilo tedy zajistit, aby v souboru `pom.xml` byl definován správný rodič (`org.jboss.teiid:connectors`) a v rodiči byl projekt `translator-simplifiedb` registrován jako modul.

6.3.2 Nastavení zásuvného modulu maven assembly plugin

Projekt Teiid je dodáván v distribucích `Teiid Runtime` nebo `Teiid Embedded`. Další dodávané produkty jsou JDBC ovladač a `Teiid Admin Shell`.

Teiid Runtime je Teiid připravený k okamžitému nasazení na aplikační server WildFly (verze 8 a vyšší), nebo Red Hat JBoss Enterprise Application Platform (verze 6.1 a vyšší). Obsahuje v sobě kromě zkompilovaných knihoven, modulů a dokumentace také výchozí konfigurační soubory včetně `standalone.xml`.

Teiid Embedded je odlehčená verze Teiidu pro použití bez aplikačního serveru, schopná běžet jako samostatná Java aplikace. Tímto bohužel přichází o vlastnosti jako například autentizace, přístup přes administraci rozhraní nebo správu připojení (connection pooling).

Sestavení těchto distribucí ze zkompilovaných artefaktů do finálních `.zip` souborů má na starosti Maven Assembly Plugin.

Z pohledu SimpleDB konektoru a překladače bylo potřeba zajistit 3 věci:

- Upravit kostru konfiguračního souboru aplikačního serveru. To znamená přidat do souboru `standalone-teiid.xml` definici resource adapteru konektoru SimpleDB a zajistit, aby překladač byl uveden v subsystému teiidu.
- Vytvořit konfigurační soubory modulů (`module descriptor`) pro každý modul překladače simpledb (api, konektor, překladač)
- Upravit konfigurační soubor, podle kterého zásuvný modul maven assembly zkompletuje výsledné `.zip` soubory. Níže je výňatek z tohoto konfiguračního souboru (tzv. assembly descriptor). V tomto konkrétním případě se jedná o instalaci artefaktu `simpledb-api` jako modulu aplikačního serveru JBoss AS (jak je vidět na řádcích 21-22):

```

1  ...
2  <moduleSet>
3    <includeSubModules>true</includeSubModules>
4    <useAllReactorProjects>true</useAllReactorProjects>
5    <includes>
6      <include>org.jboss.teiid.connectors:simpledb-api</include>
7    </includes>
8    <binaries>
9      <includeDependencies>true</includeDependencies>
10     <unpack>false</unpack>
11     <dependencySets>

```

```
12         <dependencySet>
13             <useProjectArtifact>true</useProjectArtifact>
14             <unpack>false</unpack>
15             <useTransitiveDependencies>
16                 false
17             </useTransitiveDependencies>
18             <useDefaultExcludes>true</useDefaultExcludes>
19         </dependencySet>
20     </dependencySets>
21     <outputDirectory>modules/system/layers/base/org/jboss/
22         teiid/translator/simpliedb/api/main</outputDirectory>
23     <fileMode>0644</fileMode>
24 </binaries>
25 </moduleSet>
26 ...
```

7 Quickstart

Jelikož se SimpleDB profiluje jako velmi rychlá, velmi dobře škálovatelná databáze s omezeními co se týče struktury, velikosti dat a konzistence, je její nasazení vhodné v prostředích:

- Kde je poměr čtení-zápis výrazně ve prospěch čtení – čte se často a je požadována rychlost odpovědi, zapisuje se zřídka (kvůli konzistenci)
- Kde je kladen vysoký důraz na rychlost čtení i na úkor konzistence (přístup „nevadí, že nedostanu aktuální výsledek, hlavně když jej dostanu rychle“)

Běžný přístup ve firemním prostředí je nasazení SimpleDB jako doplňkové databáze ke klasické relační databázi. V této situaci mohou být v SimpleDB uložena například metadata, případně často čtené položky.

Inspirací pro zdrojová data pro tutoriál byla firma Netflix. Netflix je firma živící se převážně streamováním filmů a seriálů a pro správu dat zvolil řešení firmy Amazon. Mezi jinými tedy i databázi SimpleDB¹.

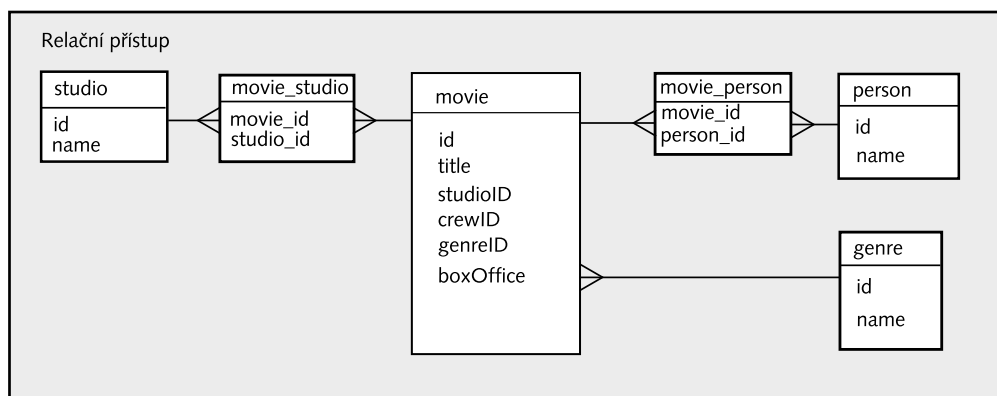
V rámci této diplomové práce byl jako zdroj dat zvolen `.csv` soubor s daty o filmech vydaných v lednu roku 2013. Soubor obsahuje:

- Název filmu
- Studio ve kterém byl film natočen (může se jednat o více studií)
- Režisér a herecké obsazení (zde se jedná o čárkami oddělené jména)
- Žánr filmu (žánrů může být více)
- Box office, aneb kolik dolarů daný film vydělal.

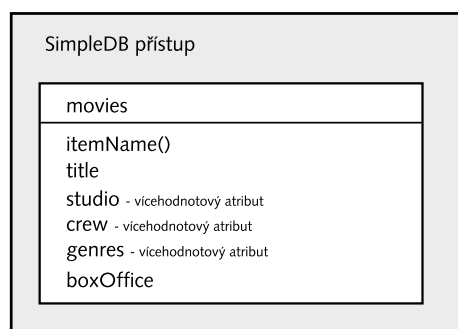
Na obrázku 7.1 je znázorněno, jakou strukturu by měla klasická relační databáze pro výše zmíněné data.

Na druhou stranu obrázek 7.2 ukazuje jak by s velkou pravděpodobností byla uložena data v databázi SimpleDB. Normalizace databáze zde nehraje roli, duplikáty nejsou na škodu. Je zde kladen důraz na jednoduchost a rychlost.

1. <http://techblog.netflix.com/search/label/SimpleDB>




Obrázek 7.1: Struktura uložení dat v relační databázi



Obrázek 7.2: Struktura uložení dat v databázi SimpleDB

Aby byly ukázány aspekty obou přístupů – jak relačního, tak přístupu z pohledu SimpleDB – jsou vzorová data uložena v databázi se strukturou ukázanou na obrázku 7.3. Takto bude možnost demonstrovat například schopnost spojování výsledků ze dvou a více vstupních množin (klauzule **JOIN** – jedna ze základních schopností relačních databází, která databáze SimpleDB nepodporuje), nebo schopnost pracovat s vícehodnotovými atributy (což je výsadou databáze SimpleDB oproti relačním databázím).



Obrázek 7.3: Výsledná (kompromisní) struktura databáze

V rámci přípravy tutoriálu byl vytvořen java program `importData`, který dokáže umístit vzorové data do uživatelské instance databáze SimpleDB. Pro snadné použití byl projekt mavenizován a pro snadnou dostupnost byl spolu s tutoriálem umístěn na server GitHub, který je určen k hostování a verzování projektů pomocí verzovacího systému Git.

Do stejného repozitáře byl také umístěn soubor `README.md` (formátovaný pomocí Markdown) obsahující vlastní tutoriál, který uživatele provede (v anglickém jazyce) nainstalováním Teiidu, vytvořením virtuální databáze, připojením k lokálně běžící instanci Teiidu a několika vzorovými dotazy na SimpleDB pomocí JDBC ovladače Teiidu.

Příloha A je pouze tutoriál převedený z Markdown do latexu. Originální Markdown soubor je v GitHub repozitáři, nebo na přiloženém CD.

8 Závěr

Výsledkem práce je funkční konektor (resource adapter) pro připojení k SimpleDB. Dále byl vytvořen modul Teiid překladače (translator) pro SimpleDB ve kterém se povedlo zvládnout problematiku mapování Teiid SQL dotazů na dotazy databáze SimpleDB. Také zde byl úspěšně řešen problém multihodnotových atributů databáze SimpleDB. Tyto části dohromady tvoří funkční modul projektu Teiid a již byly zařazeny do hlavní vývojové větve projektu. Teiid 8.7 již v sobě bude obsahovat modul pro komunikaci s databází SimpleDB vytvořený v rámci této práce.

Druhým výstupem je tutoriál v anglickém jazyce, hostovaný veřejně na serveru GitHub, který slouží jako uvedení do problematiky pro nové uživatele a demonstruje schopnosti vyvinutého Teiid modulu.

Tato práce pro mě znamenala jedny z prvních krůčků do světa open-source a velkou zkušeností pro mě byla spolupráce s lidmi, kteří programují otevřený software, jelikož bych se otevřeným softwarem rád zabýval i v budoucnu.

Dalším krokem ve vývoji Teiid modulu pro komunikaci se SimpleDB by bylo zaměření se na výkon – sepsání „performance testů“ a optimalizace kódu. Také je možnost pokusit se začlenit tutoriál vyvinutý v rámci této práce mezi oficiální „quickstarty“¹.

1. <https://github.com/teiid/teiid-quickstarts>

Literatura

- [1] *Design patterns: elements of reusable object-oriented software*. Addison-Wesley, Massachusetts, c1995. 395 s., ISBN: 02-016-3361-2.
- [2] Amazon. Amazon simpledb developer guide. <http://awsdocs.s3.amazonaws.com/SDB/latest/sdb-dg.pdf>. [cit. 2014-08-01].
- [3] James A. Larson Amit P. Seth. Federated database systems for managing distributed, heterogeneous, and autonomous databases. dostupné na <http://knoesis.wright.edu/library/download/SL90.pdf>. [cit. 2014-26-04].
- [4] Teiid developers. Teiid developer's guide. <https://docs.jboss.org/author/display/teiid86final/Developer's+Guide>. [cit. 2014-08-01].
- [5] The Apache Software Foundation. Maven assembly plugin documentation. dostupné na <http://maven.apache.org/plugins/maven-assembly-plugin/>. [cit. 2014-08-01].
- [6] Arun Gupta. *Java EE 7 Essentials*. O'Reilly Media, Sebastopol, 1 edition, 2013. ISBN: 978-1449370176.
- [7] Yury Izrailevsky. Nosql at netflix. <http://techblog.netflix.com/2011/01/nosql-at-netflix.html>. [cit. 2014-08-01].
- [8] Sun Microsystems. Java ee connector architecture specification. dostupné na http://download.oracle.com/otndocs/jcp/connector_architecture-1.6-fr-eval-oth-JSpec/. [cit. 2014-08-01].
- [9] James Murty. *Programming Amazon Web Services: S3, EC2, SQS, FPS, and SimpleDB*. O'Reilly, Sebastopol, c2008. 582 s. ISBN: 05-965-1581-2.
- [10] Margaret Rouse. Exploring data virtualization tools and technologies. dostupné na <http://searchdatamanagement.techtarget.com/definition/data-virtualization>. [cit. 2014-26-04].

- [11] John Ferguson Smart. *Java Power Tools*. O'Reilly, Sebastopol, c2009. ISBN: 978-0-596-52793-8.
- [12] Sonatype. *Maven: the definitive guide*. O'Reilly, Sebastopol, 1 edition, c2008. 452 s., ISBN: 978-0-596-51733-5.
- [13] Guarav Vaish. *Nosql starter*. Packt Publishing Limited, 1 edition, 2013. ISBN: 978-1849694988.

A Tutorial

This is quickstart for SimpleDB connector and translator for Teiid - <https://github.com/teiid/teiid>

System Requirements

To run this quickstart with the provided build scripts, you need the following:

1. Java 1.6 or better, to run JBoss AS and Maven. You can choose from the following:
 - OpenJDK
 - Oracle Java SE
 - Oracle JRockit
2. Maven 3.0.0 or newer, to build and deploy the example
 - If you have not yet installed Maven, see the Maven Getting Started¹ Guide for details.
 - If you have installed Maven, you can check the version by typing the following in a command line:
`mvn -version`
3. The JBoss Enterprise Application Platform (EAP) 6.1 (and higher) distribution ZIP or the JBoss AS 7.2 (or WildFly 8 or higher) distribution ZIP.
 - For information on how to install and run JBoss, refer to the server documentation.
4. Amazon AWS credentials
 - If you don't have one, go to aws.amazon.com and sign up for using Amazon SimpleDB

1. <http://maven.apache.org/guides/getting-started/index.html>

- Your access credentials can be found on <https://portal.aws.amazon.com/gp/aws/securityCredentials>
5. Client for executing queries against Teiid
 - Some JDBC client. This is preferred variant. This example will be demonstrated using Squirrel SQL client - <http://squirrel-sql.sourceforge.net/>
 - Some tool for executing queries directly to Teiid. For example simpleclient from teiid-quickstarts github repository - <https://github.com/teiid/teiid-quickstarts>

Installing Teiid

Project Teiid (version 8.6) is compatible with EAP 6.1 or WildFly 8².

1. Install application server (by uncompressing it to desired folder)
2. Download latest Teiid Runtime from <http://www.jboss.org/teiid/downloads> and install it
 - Installing teiid is just matter of extracting into WildFly or EAP directory.
3. Add connection definition to resource adapter
 - Open `$AS_ROOT_DIRECTORY/standalone/configuration/standalone-teiid.xml` in your favourite text editor
 - Add this snippet under `simplifiedb` resource adapter to look like so (do not forget to fill your access key id & access key):

```
<resource-adapter id="simplifiedb">
  <module slot="main"
    id="org.jboss.teiid.resource-adapter.simplifiedb"/>
  <connection-definitions>
    <connection-definition
      class-name="org.teiid.resource.adapter.simplifiedb.
```

2. As SimpleDB support will be in Teiid since version 8.7 (and 8.7 is not out yet) you may need to compile teiid from source code as described in here: <https://community.jboss.org/wiki/TeiidEclipseDevEnvironmentSetUpAndBuildingRuntimeArtifacts>

```
SimpleDBManagedConnectionFactory"
jndi-name="java:/simpledb" enabled="true"
use-java-context="true" pool-name="fileDS">
  <config-property name="AccessKey">
    <YOUR_ACCESS_KEY_ID>
  </config-property>
  <config-property name="SecretAccessKey">
    <YOUR_SECRET_ACCESS_KEY>
  </config-property>
</connection-definition>
</connection-definitions>
</resource-adapter>
```

- Create virtual database file (VDB) and deploy it:
 - Create file `my-vdb.vdb` with content:

```
<?xml version="1.0" encoding="UTF-8" standalone="yes"?>
<vdb name="Test" version="1">

  <description>Test</description>
  <model name="Test">
    <source name="simpledb-connector"
      translator-name="simpledb"
      connection-jndi-name="java:/simpledb"/>
  </model>
</vdb>
```
 - Save this file to your AS deploy folder (`$AS_ROOT_DIRECTORY/standalone/deployments/my-vdb.vdb`)

Prepare sample data in your SimpleDB database


1. Clone git repository <https://github.com/rhopp/teiidSimpleDBQuickstart>
2. In root folder (the one with `pom.xml` in it) run

```
mvn verify -DkeyID=<yourKeyID> -DsecretKey=<yourSecretKey>
```


This should create 3 domains in you SimpleDB Database

- `movies` database of movies
- `people` database of actors and directors

- `people_movies` intersection table for m to n relationship between movies and people:

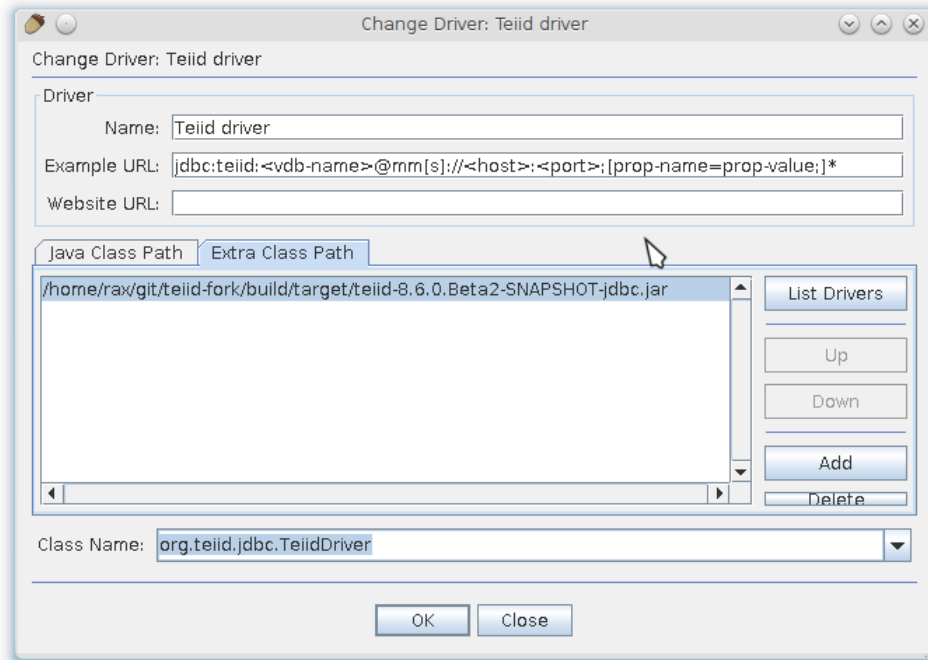


Which translates into:



Running the example

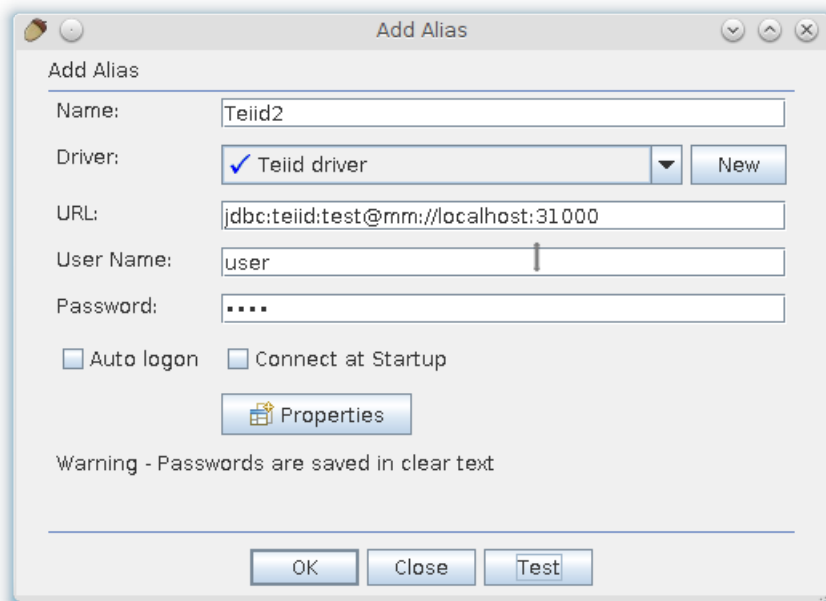
- Install Squirrel SQL client
- Download and install Teiid JDBC driver into Squirrel SQL client
 - Download Teiid JDBC driver from <http://www.jboss.org/teiid/downloads>
 - Create new driver in Squirrel SQL Client
 - Add Teiid JDBC Driver jar into Extra class path
 - As class name put `org.teiid.jdbc.TeiidDriver` as shown on figure A.1
- Start Teiid



Obrázek A.1: New driver settings

- Start your application server like `bin/standalone.sh -c standalone-teiid.xml`
 - If everything went right, something like `TEIID40003 VDB Test.1 is set to ACTIVE` should appear in application server log. This means, that virtual database is successfully deployed, connection to SimpleDB was successful and all metadata were loaded.
- (d) Connect Squirrel SQL client to running Teiid
- Create new alias in Squirrel SQL Client
 - As driver choose Teiid driver, created in step 2.
 - URL is `jdbc:teiid:test@mm://localhost:31000`
 - Default values for username and password are `user`, `user`

- Everything should look like on figure A.2. Now you can test the connection and save it.



Obrázek A.2: New alias settings

- (e) Now you can try to execute SQL queries like:
- `SELECT * FROM people WHERE director=true` for list of all directors
 - or

```
SELECT movies.title FROM movies
  INNER JOIN people_movies
    ON movies."itemName()"=people_movies.movieId
  INNER JOIN people
    ON people_movies.personId=people."itemName()"
 WHERE people.name='Emma Stone'
```

for movie titles where Emma Stone was involved.
 - Let's try to add some movie:

```
INSERT INTO movies
VALUES ('00021', '[Action;Comedy]',
      'My Studio', 'My movie', '5000')
```

Note here, that the second value will be stored as multi-valued attribute. Format for working with multivalued attributes is semicolon separated values enclosed in brackets.

- Oh... Typo in movie title! Let's change that!

```
UPDATE movies SET "title"='My movie'
WHERE "itemName"='00021'
```
- Want to delete movie from domain? No problem:

```
DELETE FROM movies WHERE "itemName"='00021'
```

B Obsah přiloženého CD disku

- Složka `teiid-fork` s kompletními zdrojovými kódy projektu Teiid obsahující již změny provedené v rámci této práce.
- Soubor `teiidDiff` – soubor obsahující všechny změny provedené v rámci této práce (výstup příkazu `git diff`)
- Složka `importData` obsahující v sobě zdrojová data, projekt pro import dat do SimpleDB a soubor `README.md`, ve kterém je obsažen tutoriál