Masarykova univerzita Fakulta informatiky



Relační přístup k Amazon SimpleDB

DIPLOMOVÁ PRÁCE

Radim Hopp

Prohlášení

Prohlašuji, že tato diplomová práce je mým původním autorským dílem, které jsem vypracoval samostatně. Všechny zdroje, prameny a literaturu, které jsem při vypracování používal nebo z nich čerpal, v práci řádně cituji s uvedením úplného odkazu na příslušný zdroj.

Radim Hopp

Vedoucí práce: doc. RNDr. Tomáš Pitner, Ph.D.

Poděkování

Rád bych poděkoval vedoucímu práce panu doc. Pitnerovi za ochotný přístup a věnovaný čas, dále také kolegům Filipovi Nguyenovi a Filipovi Eliášovi za vedení a směrování převážně v implementační části práce.

Shrnutí

Cílem práce je prozkoumání možností relačního přístupu k NoSQL databázi Amazon SimpleDB, konkrétně mapování Teiid SQL dotazů na dotazy databáze Amazon SimpleDB. V rámci práce byl implementován fungující modul do projektu Teiid schopný základních CRUD operací nad databází SimpleDB. Dalším výstupem práce je tutoriál demonstrující instalaci, nastavení a základní použití vytvořeného modulu.

Klíčová slova

Amazon Simple
DB, JBoss Teiid, JBoss, databáze, relační přístup, No
SQL $\,$

Obsah

1	Úvo	d
2	JBo	ss Teiid
	2.1	Systémy datové federace
	2.2	JBoss Teiid a datová federace
	2.3	Části projektu JBoss Teiid 6
	2.4	Příklad datové federace v projektu Teiid 8
3	Ama	azon SimpleDB
	3.1	Struktura databáze SimpleDB
	3.2	Vlastnosti databáze Amazon SimpleDB
		3.2.1 SimpleDB jako služba
		3.2.2 Flexibilita
		3.2.3 Indexování
		3.2.4 Konzistence
		3.2.5 Omezení databáze SimpleDB
4	Kon	nunikace s databází Amazon SimpleDB
	4.1	Přehled příkazů SimpleDB
	4.2	Podmíněné vkládání a mazání dat
	4.3	Bezpečnost
		4.3.1 Proces autentizace
	4.4	Výběr knihovny pro komunikaci s databází SimpleDB 16
5	Map	oování Teiid dotazů na SimpleDB dotazy
	5.1	Vícehodnotové atributy
	5.2	SELECT
	5.3	INSERT
	5.4	<i>UPDATE</i>
	5.5	<i>DELETE</i>
6	Imp	lementace
	6.1	Konektor
		6.1.1 Modul simpledb-api
		6.1.2 Modul connector-simpledb
	6.2	Překladač
		6.2.1 SimpleDBExecutionFactory
		6.2.2 Executory
		6.2.3 Visitory
	6.3	Sestavení

	6.3.1 Konfigurace jednotlivých SimpleDB modulů	33
	6.3.2 Nastavení zásuvného modulu maven assembly plugin	33
7	Quickstart	36
8	Závěr	39
A	Tutoriál	42
В	Obsah přiloženého CD disku	49

1 Úvod

Opensource projekt JBoss Teiid je silným nástrojem pro usnadnění a zkvalitnění práce aplikací nad více heterogenními zdroji dat. Aplikacím poskytuje jednotné rozhraní pro práci s daty a zajištuje komunikaci s jednotlivými zdroji dat.

Teiid již umí komunikovat s nejčastěji používanými zdroji dat, jakými jsou například relační databáze, LDAP či data uložena v souborech na disku. Bohužel ale nebyl prozatím vytvořen žádný modul do projektu Teiid pro komunikaci s NoSQL databází Amazon SimpleDB ikdyž po takovémto modulu byla poptávka už v roce 2010^1 .

Jedním z důvodů, proč tento modul ještě nebyl vytvořen může být jeho netriviálnost. Jelikož je SimpleDB takzvanou NoSQL databází, což znamená, že nevychází z klasického modelu tabulek a relací mezi nimi, a jelikož Teiid ze své přirozenosti přistupuje k datům relačně, vyvstává zde několik možných problémů, které se tato práce snaží řešit.

Nejprve práce uvede čitatele do problému seznámením s projekty JBoss Teiid a Amazon SimpleDB, jejich fungováním, strukturou a fungováním.

Stěžejní částí teoretické práce je prezentace způsobu mapování Teiid SQL dotazů na dotazy a příkazy databáze Amazon SimpleDB. V této sekci nalezne čtenář řešení například absence schopnosti databáze SimpleDB spojit dvě tabulky (v SQL jde o klauzuli JOIN).

Praktická část práce detailně popisuje konkrétní implementaci modulů pro připojení a komunikaci s databází SimpleDB.

Součástí práce je také tutoriál, který čtenáře provede instalací projektu Teiid, jeho základním nastavením pro použití s implementovaným modulem, připojením k databázi SimpleDB a provedením základních i komplikovanějších dotazů proti databázi pomocí projektu Teiid nad vzorovými daty. V textu práce je popsána struktura vzorových dat a zdůvodněna jejich volba.

^{1.} V připomínkovacím systému JIRA projektu Teiid byl vytvořen požadavek už v dubnu 2010 – https://issues.jboss.org/browse/TEIID-1070

2 JBoss Teiid

JBoss Teiid je otevřený software pro virtualizaci dat z více zdrojů. Tento projekt je zaštitován v rámci JBoss komunitních projektů¹ spolu s projekty jako WildFly nebo GateIn².

Firma Red Hat nabízí také plně podporovanou a certifikovanou verzi pod názvem Red Hat JBoss Data Virtualization (dříve nazývaný Red Hat JBoss Enterprise Data Services Platform). Tento produkt kromě mírně upraveného komunitního projektu Teiid v sobě obsahuje také JBoss Enterprise Application Platform (aplikační server založený na komunitním projektu WildFly) a další produkty³

2.1 Systémy datové federace

Datová federace úzce souvisí s datovou virtualizací (přesněji řečeno je její specializací).

Datová virtualizace je pojem popisující jakýkoliv přístup k řízení dat, který umožňuje aplikaci získávat data a manipulovat s nimi bez znalosti technických detailů, jako třeba jak jsou formátována či kde jsou fyzicky uložena. [10, volně přeloženo]

Takto definovaná virtualizace dat neříká nic o dílčích databázích či systémech, pouze říká, že existuje abstraktní vrstva, která zastiňuje strukturu, implementaci nebo třeba jazyk komunikace s databází. Takovouto vrstvou může být například aplikace komunikující s databází a vnějšku poskytující REST rozhraní.

Datová federace poskytuje přístup k více heterogenním **autonomním** zdrojům dat. To znamená, že jednotlivým zdrojům dat je v nějaké míře zajištěna samostatnost (což v případě obecné virtualizace dat nemusela být pravda). Je to tedy forma virtualizace dat (je její specializací).

^{1.} http://www.jboss.org/overview/

^{2.} kompletní seznam projektů na http://www.jboss.org/projects

^{3.} kompletní seznam produktů a projektů obsažených v Red Hat JBoss Data Virtualization i s použitými verzemi k naleznutí na https://access.redhat.com/site/articles/703673

Software zajišťující manipulaci s dílčími databázovými systémy v rámci datové federace se nazývá **systém datové federace** (FDBMS - Federated database management system)[3]. Tento software by měl splňovat několik základních požadavků:

• Virtualizace dat

Jelikož je datová federace specializací datové virtualizace, měl by také software pro datovou federaci odstiňovat aplikace k němu přistupjící od implementačních, strukturních či jiných detailů jednotlivých databází a databázových systémů.

Samostatnost dílčích systémů

Oproti "čisté" virtualizaci zaručuje systém datové federace jednotlivým databázovým systémům a zdrojům dat jistou autonomii. To znamená, že k jednotlivým podsystémům by se mělo dát přistupovat také samostatně, bez využití systému datové federace.

Schopnost pracovat s heterogenními systémy

Vedle autonomie jednotlivých subsytémů je dalším hlavním úkolem systémů datové federace schopnost komunikovat a pracovat s heterogenními systémy. Jednotlivé systému můžou být například soubory na disku, data přístupná z REST rozhraní či třeba SQL databáze. Je patrné, že ke každému z těchto datových systémů je nutné přistupovat různě. Zodpovědnost za správnou interpretaci dat nezávisle na schéma, implementaci, či rozdíly v datových typech jednotlivých systémů tak leží na bedrech systému datové federace.

2.2 JBoss Teiid a datová federace

Datové federace v nástroji JBoss Teiid je dosaženo pomocí agregace jednotlivých datových zdrojů do virtuálních databází (VDB). Tyto virtuální databáze jsou definovány pomocí XML souborů jejichž tvorba je jedním z hlavních případů užití nástroje Teiid Designer. Ten poskytuje sadu nástrojů pro snadnou tvorbu i složitějších virtuálních databází a jejich schémat. Druhý možný přístup je tvorba takzvaných dynamických virtuálních databází (Dynamic VDB). Takto definované virtuální

databáze načítají své schéma samostatně pomocí překladačů (pomocí metody getMetadata() popsané v kapitole 6.2.1). Od verze 8.0 projektu Teiid je možné v dynamických VDB definovat schéma také pomocí jazyka pro definici dat⁴ [4, Reference Guide → VDBs → DDL Metadata].

Konflikty v pojmenování mezi jednotlivými zdroji jsou v projektu Teiid řešeny odkazováním nejen na tabulku, respektive tabulku a sloupec, ale také na schéma.

2.3 Části projektu JBoss Teiid

V této části budou stručně popsány hlavní části projektu JBoss Teiid. Přímé součásti projektu jsou: Query engine, JDBC ovladač, server, konektory a překladače. Tyto části spolu poskytují vše potřebné k virtualizaci a integraci dat z různých zdrojů. Dále je v rámci projektu Teiid distribuována webová konzole, zásuvný modul pro RHQ⁵ a AdminShell, které usnadňují vývoj a práci s nástrojem Teiid. Také zde bude krátká zmínka o samostatném projektu JBoss Teiid Designer.

• Query engine

Jedná se o srdce projektu, které zpracovává relační, XML, XQuery a jiné dotazy ze zdrojů dat. Také zajišťuje podporu pro schémata vytvořené z jednoho, či z více různých zdrojů dat. V neposlední řadě se query engine stará o transakce a uživatelem definované funkce.

JDBC ovladač

JDBC ovladač slouží pro jednoduché použití Teiidu v externích java aplikacích.

Server

Tato část je zodpovědná za běh query enginu v rámci aplikačního serveru (WildFly nebo Red Hat JBoss Enterprise Application Platform) a zaručuje škálovatelnost a snadnou správu. Součástí je administrační konzole, ve které je možno jednoduše nastavit

^{4.} DDL - Data Definition Language

^{5.} RQH je komunitní projekt vedený pod jboss.org pro správu více serverů, http://www.jboss.org/rhq

například nasazenou virtuální databázi nebo nastavení vláken query enginu.

Konektory a překladače

Teiid přichází se sadou konektorů a překladačů (connectors & translators), díky kterým je schopen napojit se na řadu různých zdrojů dat. Konektory zajišťují napojení na zdroj dat, překladače potom obstarávají získávání dat podle Teiid požadavků. Základním kamenem jsou konektory pro většinu relačních databází, webové služby, textových souborů a LDAP⁶.

Cíl této diplomové práce je rozšířit tuto sekci o konektor pro NoSQL databázi Amazon SimpleDB.

• Nástroje

- Teiid Designer

Teiid Designer je samostatný projekt (není součástí projektu JBoss Teiid), který ovšem také patří mezi komunitní projekty jboss.org. Jedná se o sadu zásuvných modulů pro vývojové prostředí Eclipse, které mimo jiné usnadní vývoj virtuálních databází (pohledy, procedury, ...)

Nástroje pro monitorování a správu

Dvěmi hlavními nástroji pro monitorování a správu jsou Teiid Web Console (v zásadě jde o rozšíření webové konzole aplikačního serveru o položky pro správu a monitorování Teiid instance) a zásuvný modul pro RHQ pro kontrolu více serverů či clusterů Teiidu.

Skriptování

V rámci Teiidu je také distribuován Teiid AdminShell, což je skriptovací nástroj založený na jazyku Groovy. AdminShell umožňuje spravovat Teiid z příkazové řádky či pomocí skriptu, což uživateli velmi usnadní provádění často se opakujících činností.

^{6.} Lightweight Directory Access Protocol)

2.4 Příklad datové federace v projektu Teiid

Zde bude uveden velmi jednoduchý příklad agregace dat z více zdrojů do jedné virtuální databáze. Příklad zjednodušeně simuluje systém pro prodej produktů jednotlivým osobám. Jako jeden zdroj mějme jednoduchý textový soubor uchovávající informace o osobách ve formátu:

Person		
id	name	

Tabulka 2.1: Schéma tabulky Person

Jako další zdroj v tomto příkladu poslouží databáze SimpleDB se dvěma doménami (význam domén je blíže popsán v kapitole 3.1) Product a Transaction:

Product					
id	name	price			

Tabulka 2.2: Schéma tabulky Product

Transaction			
id_person	$id_product$	quantity	

Tabulka 2.3: Schéma tabulky Transaction

V této chvíli je možno použít buď Teiid Designer pro nadefinování virtuální databáze (vytvoření XML souboru definující tuto virtuální databázi) nebo vytvořit XML soubor ručně, který definuje dynamickou virtuální databázi. V tomto příkladě bude zvolena druhá možnost a daný XML souboru je uveden v ukázce 1

Ukázka 1: Ukázka XML souboru my-vdb.xml

Takto nadefinovaná virtuální databáze může již být předložena nástroji Teiid a následně již může být nástroj Teiid dotazován na data z obou zdrojů jako například dotaz uvedený v ukázce 2.4

```
SELECT person.name, prod.name, trans.quantity
FROM person.person as person
INNER JOIN product_transaction.transaction as trans
ON trans.id_person=person.id
INNER JOIN product_transaction.product as prod
ON prod.id=trans.id_product
WHERE per.id=5
```

Ukázka 2: Ukázka SQL dotazu na virtuální databázi

Tento příklad slouží pouze k základnímu pochopení datové federace v nástroji JBoss Teiid. Rozsáhlejší příklad i s detailnějším popisem postupu od návrhu virtuální databáze, přes nasazení až k fungování virtuální databáze je popsán v kapitole 7 a příloze A

3 Amazon SimpleDB

SimpleDB je databáze z dílen firmy Amazon a patří do skupiny produktů Amazon Web Services. Tato databáze je takzvaná NoSQL, což znamená, že data v ní jsou uložená ve formátu, jaký není běžný pro relační databáze (tabulky, sloupce, řádky) a nepodporuje relace. SimpleDB je poskytována firmou Amazon jako služba a tudíž není možné nasadit databázi SimpleDB na vlastním serveru, ale běží pouze na serverech firmy Amazon.

3.1 Struktura databáze SimpleDB

Strukturu SimpleDB databází je možno přirovnat k tabulkovému procesoru.

• Uživatelský účet (Customer Account)

V rámci jednoho účtu lze mít více domén stejně jako v rámci jednoho souboru tabulkového procesoru je možno mít více listů s tabulkami.

• Doména (Domain)

Analogie k jedné tabulce v tabulkovém procesoru. Obsahuje řádky (položky), sloupce (atributy) a jednotlivé buňky (hodnoty).

Položky (Items)

Řádky tabulky. Reprezentují jednotlivé objekty uložené v databázi s jedním, či více vyplněnými atributy.

• Atributy (Attributes)

Sloupce tabulky. Určují kategorie dat, jakých můžou položky nabývat.

Hodnoty (Values)

Hodnoty si lze představit jako jednotlivé buňky tabulky. Tady se ovšem analogie s tabulkovým procesorem rozchází, neboť jedna "buňka" může nabývat více hodnot najednou.

Navíc má každý prvek domény (řádek tabulky) povinný atribut ItemName, který musí být v dané doméně unikátní.

SimpleDB nepoužívá žádné jiné datové typy kromě typu String, takže i čísla jsou v databázi uloženy a je s nimi nakládáno jako s textovými řetězci. To s sebou nese řadu problémů a hlavně zátěž na vývojáře aplikace tyto problémy řešit. Typickým příkladem takového problému je, že čísla nejdou řadit lexikograficky (lexikograficky: 10<2, což je špatně). Řešením je doplnění nul před čísla (00010>00002, což je správně).

3.2 Vlastnosti databáze Amazon SimpleDB

3.2.1 SimpleDB jako služba

Databáze Amazon SimpleDB je dodávaná jako služba. To znamená, že Amazon neposkytuje možnost nasadit tuto databázi ve vlastním prostředí, ale provozuje ji pouze na svých serverech. Uživatel databáze se tedy nemusí starat o nastavování ani o hardware, ale například ani o škálování, nebo o replikaci dat, jelikož Amazon automaticky distribuuje a synchronizuje data v několika datových centrech umístěných v různých geografických zónách, čímž omezuje nejen riziko ztráty dat, ale také zvyšuje rychlost přístupu k datům v různých místech na světě. Tím pádem se může uživatel databáze plně zaměřit na práci s vlastními daty.

3.2.2 Flexibilita

Flexibilita je další z výhod databáze Amazon SimpleDB. Jelikož je to NoSQL databáze, není potřeba mít pevně dané schéma, jak tomu bývá u SQL databází, ale nové atributy a entity mohou být přidávány takzvaně za pochodu.

3.2.3 Indexování

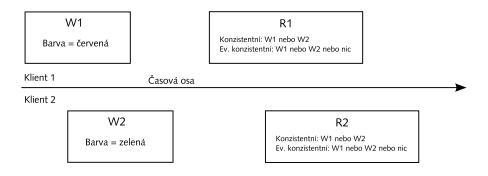
SimpleDB automaticky indexuje veškerá data v ní uložené, čímž tato povinnost odpadá z beder vývojářů aplikace a zvyšuje rychlost navracení výsledků čtecích operací.

3.2.4 Konzistence

Amazon pro zápis zaručuje konzistenci takovou, že úspěšně provedený zápis (použitím příkazů jako např. PutAttributes, BatchPutAttributes, CreateDomain, ...) znamená, že všechny kopie databáze byly změněny. Toto pojetí konzistence ovšem nezaručuje chování při překrytí dvou či více zápisů najednou. Pouze zaručuje, že výsledné data budou na všech kopiích databáze rovná hodnotě jednoho z těchto zápisů (toho, který databáze obdržela nejpozději). Toto bude níže ilustrováno na příkladě. Při čtení si uživatel může zvolit mezi konzistentním a eventuálně konzistentním čtením. Konzistentní čtení zaručuje, že vrátí hodnotu po provedení posledního dosud přijatého zápisu. Eventuálně konzistentní čtení na druhou stranu vrátí hodnotu, která je aktuálně uložená na dotazovaném serveru (tj. může vrátit již neplatnou hodnotu).

Příklad konzistence

Na obrázku 3.1 je uveden příklad, kdy se překrývají dva zápisy. V této situaci není možné určit, jestli po provedení obou zápisů bude výsledná hodnota atributu Barva rovna červená, nebo zelená z toho důvodu, že není zaručeno, kterou instrukci zpracuje SimpleDB jako první. Například kvůli vysoké latenci sítě prvního klienta bude nejprve přijata a zpracována instrukce W2 druhého klienta a následně přepsána instrukcí W1, tedy veškeré následné konzistentní čtení vrátí Barva=červená.



Obrázek 3.1: Ilustrace chování databáze SimpleDB

Jak bylo ukázáno, konzistentní čtení v tomto případě mohlo vrátit jak výsledek W1, tak výsledek W2. Oproti tomu, výsledek eventuálně konzitentního čtení může být kromě W1 či W2 také nic. Pravděpodobnost prázdného výsledku se s časem minimalizuje, neboli čím déle po zápisu je čteno, tím větší je pravděpodobnost korektního výsledku.

Základní rozdíl mezi konzistentním a eventuálně konzistentním čtením lze shrnout do tabulky $3.1\,$

Eventuálně konzistentní čtení	Konzistentní čtení
Možné nekorektní výsledky	Vždy korektní výsledek
Rychlejší odezva	Možná pomalejší odezva
Větší datová propustnost	Možná menší datová prostupnost

Tabulka 3.1: Tabulka vlastností konzistentního a ev. konzistentního čtení

3.2.5 Omezení databáze SimpleDB

Kromě výše zmíněného chování, které by se v jistých situacích dalo považovat za omezení, je asi největším omezením velikost domény, jak co se místa na disku týče, tak také maximální počet atributů. Konkrétně je horní hranice 10 GB pro data a 1 miliarda atributů na jednu doménu. Domén je možno vytvořit až 250 na jeden uživatelský účet.

4 Komunikace s databází Amazon SimpleDB

V této kapitole jsou popsány základní kameny komunikace s databází Amazon SimpleDB jako jsou například příkazy, zabezpečení či autentizace. Tyto poznatky jsou dále použity v implementační části (kapitola 6)

4.1 Přehled příkazů SimpleDB

- CreateDomain slouží k vytvoření nové domény.
- **DeleteDomain** vymaže danou doménu.
- **ListDomains** vrátí seznam domén asociovaných s daným uživatelským účtem.
- **DomainMetadata** slouží k získání informací o doméně (datum vytvoření, počet položek v doméně, počet atributů, ...)
- **PutAttributes** vloží novou položku s danými hotnotami atributů, či upraví již stávající položku.
- Select se podobá běžnému SELECT příkazu, který je dobře známý z SQL jazyků. Je ovšem mírně omezen a to například absencí JOIN klauzule. Přesný přehled možností příkazu SELECT databáze SimpleDB je uveden v dokumentaci¹
- **GetAttributes** vrátí hodnoty požadovaných atributů jedné dané položky. Umožňuje specifikovat jeden, či více požadovaných atributů, nebo také všechny atributy dané položky.

4.2 Podmíněné vkládání a mazání dat

SimpleDB v aktuální verzi (od 24. února 2010) podporuje takzvaný podmíněný zápis a mazání dat.

Při tomto podmíněném zápise (mazání) se spolu s běžnými parametry odešle také podmínka a očekávaný výsledek vyhodnocení dané podmínky.

^{1.} http://awsdocs.s3.amazonaws.com/SDB/latest/sdb-dg.pdf

Zápis se poté provede pouze tehdy, je-li vyhodnocená podmínka rovna očekávanému výsledku.

Tato vlastnost se dá použít například pro implementaci čítače (přečte aktuální stav čítače a pokusí se zapsat nový stav čítače za podmínky, že stav čítače byl nezměněn), což by bez podmíněného vložení byl netriviální úkol. Také se tímto rozšiřují možnosti kontroly konkurenčního přístupu k datům (pomocí optimistických protokolů "optimistic concurrency control").

4.3 Bezpečnost

Pro autentizaci má každý uživatel "ID přístupového klíče" (20 alfanumerických znaků) a "tajný přístupový klíč" (40 alfanumerických znaků), kterými podepisuje kažý požadavek vůči SimpleDB. Sama Amazon SimpleDB nemá nástroj pro autorizaci, ten je ovšem integrován do správy identit a přístupu AWS (AWS Identity and Access Management - systém pro správu uživatelů a jejich práv v rámci celého AWS), takže je možné omezit práva jednotlivým uživatelům. Jediným problémem může být skutečnost, že nelze definovat přístupové práva pro jiný AWS účet – pro každého uživatele domény musí být vytvořen uživatel v rámci AWS účtu vlastnícího doménu.

4.3.1 Proces autentizace

- 1. Vytvoření řetězce dotazu
- 2. Kanonizování řetězce dotazu (seřazení parametrů, zakódování parametrů a jejich hodnot URL kódováním²), . . .)
- 3. Vypočítání HMAC³ z kanonizovaného textového řetězce za použití "tajného přístupového klíče" jako klíče a SHA256 nebo SHA1 jako hashovacího algoritmu. Tento podpis se připojí k původnímu požadavku jako parametr signature spolu s ID přístupového klíče jako AWSAccessKeyId.

Zde je ukázán proces autentizace pouze zjednodušeně. Přesný návod jak sestrojit validná požadavek je dostupný v dokumentaci SimpleDB.

^{2.} Podle RFC 3986, kapitola 2 – http://tools.ietf.org/html/rfc3986

^{3.} Podle RFC 2104 – http://www.ietf.org/rfc/rfc2104.txt

4.4 Výběr knihovny pro komunikaci s databází SimpleDB

Existují tři hlavní způsoby komunikace s databází SimpleDB v jazyce Java a to přímé volání REST API (popsaném v kapitole 4), použití oficiálního Java API poskytovaného a podporovaného přímo společností Amazon nebo použití JDBC ovladače.

Nejprve se budu věnovat JDBC ovladači. Tento poměrně běžný a standartní způsob komunikace Java programů s databázemi by se mohl zdát jako nejlepší a nejjednodušší řešení. Toto tvrzení by podporoval i fakt, že jedna ze základních funkcionalit projektu Teiid je i konektor a překladač pro JDBC drivery. Lze tak "podstrčit" projektu Teiid jar soubor s JDBC ovladačem pro Amazon SimpleDB a vlastnostmi nutnými pro připojení (ID přístupového klíče a tajný přístupový klíč) a Teiid se již postará o vše ostatní. Hlavním argumentem proti použití JDBC ovladače je fakt, že se jedná o již prakticky mrtvý projekt⁴, který byl vyvíjen pouze jedním člověkem. O "mrtvosti" projektu svědčí déle než 4 roky netknuté bugy v připomínkovacím systému (anglicky Issue tracker, dostupný na stránce projektu). Tento přístup také za ostatními dvěma alternativami zaostává na poli podpory. Kdežto Java API i REST API jsou podporovány přímo firmou Amazon, není zde, u JDBC ovladače, žádné záruky, že bude podporován do budoucna.

Tímto je zavrhnuto použití JDBC ovladače a zbývá rozhodnout, zda přistupovat k SimpleDB přímo pomocí volání REST API nebo pomocí Java API. Co se týče podpory, jsou na tom oba tyto přístupy stejně (oba oficiálně podporované firmou Amazon). V této práci bylo nakonec zvoleno Java API, převážně kvůli komfortu práce s kódem a následné čitelnosti kódu. Kdyby bylo použito přímé volání REST API, bylo by vhodné sepsat si vlastní Java API, což by zbytečně rozšiřovalo kódovou základnu projektu. Použití Java API z pohledu rozšíření kódu znamená pouze pár řádků v Maven konfiguraci, neboť je tato knihovna přítomna v Maven centrále⁵

^{4.} Webová stránka projektu: https://code.google.com/p/simpledb-jdbc/ a https://github.com/beacon50/SimpleJDBC

^{5.} Detailně popsáno v kapitole 6.3

5 Mapování Teiid dotazů na SimpleDB dotazy

V této kapitole bude obecně ukázáno, jakým způsobem byly mapovány Teiid dotazy na dotazy databáze SimpleDB. Konkrétně se jedná o příkazy SELECT, INSERT, UPDATE a DELETE.

5.1 Vícehodnotové atributy

Teiid přistupuje k datům jako běžná relační databáze, tedy jednomu řádku a sloupci odpovídá nejvýše jedna hodnota. Z tohoto důvodu je nutné ošetřit přístup k vícehodnotovým atributům. Nabízí se několik řešení:

- 1. Byl-li by dopředu znám maximální počet hodnot u jednotlivých atributů, mohl by Teiid vnímat vícehodnotové atributy jako více sloupců tabulky (pro každou z možných hodnot jeden sloupec). Tímto přístupem by se ovšem zafixovalo schéma a přišli bychom o jednu z hlavních výhod databáze SimpleDB (SimpleDB netrvá na pevném schématu).
- 2. Zakódovat všechny hodnoty vícehodnotového atributu do jediného textového řetězce, který by byl lidsky i strojově čitelný. Tímto odpadá problém se změnou počtu hodnot atributu.

Ve finální implementaci byl zvolen druhý přístup a hlouběji bude probrán v kapitole 6.

5.2 SELECT

Jelikož SimpleDB podporuje mírně omezený SELECT, stačí vždy pouze poupravit řetězec příkazu SELECT generovaný Teiidem, aby byl srozumitelný pro SimpleDB. Naštěstí lze pro každý překladač nadefinovat sadu podporovaných vlastností. Nepodporované vlastnosti obslouží sám Query Engine (např. překladač nepodporuje JOIN klauzuli. Query Engine tedy rozloží dotaz s JOIN klauzulí na dva jednoduché dotazy, ty poté předá překladači a výsledné data zpracuje programově v paměti).

```
select output_list
from domain_name
where [expression]
[sort_instructions]
limit [limit]
```

Ze struktury je zřejmé, že žádné velké změny nebude třeba provádět. Je nutné definovat, že překladač nepodporuje JOIN klauzuli a poté zajistit, aby byly korektně prováděny jednoduché SQL dotazy na které byl původní dotaz rozložen. Zde vyvstává pár problémů:

1. Dotazu obsahujícímu atribut itemName() (povinný unikátní atribut, který má každá položka) musí být tento atribut odebrán – tento atribut je automaticky vracen v odpovědi databáze ikdyž není specifikován. Naopak pokud je požadován spolu s jinými atributy, databáze vrátí chybu. Toto platí s výjimkou dotazu, kdy je itemName() jediným požadovaným atributem.

Tento dotaz je korektním dotazem na databázi SimpleDB a vrátí hodnoty atributu itemName() všech položek v doméně TestDomain:

```
SELECT itemName() FROM TestDomain
```

Tento dotaz vrátí chybovou hlášku InvalidQueryExpression:

```
SELECT itemName(), attribute1 FROM TestDomain
```

2. Další problém může vyvstat ve WHERE části výrazu. Těmto potížím se dá vyhnnout správným nastavením schopností překladače.

5.3 INSERT

Zde je situace stále celkem jednoduchá, neboť INSERT vždy vkládá jeden nový řádek, což je téměř ekvivalentní příkazu PutAttributes. Je zde akorát potřeba získat z Teiid příkazu INSERT seznam sloupců, jejich hodnot a název domény do které má proběhnout vložení. Vzhledem ke zvolenému řešení problému vícehodnotových atributů není nutné se jimi zaobírat zde (logika obsluhy vícehodnotových atributů je v implementaci extrahována do samostatného modulu).

5.4 UPDATE

U UPDATE je situace poněkud složitější, neboť je možné měnit více položek najednou (díky WHERE klauzuli) a příkazy PutAttributes a BatchPutAttributes neumožňují měnit více položek specifikovaných pomocí kritéria najednou. Je tedy nutné nejprve pomocí SELECT příkazu nad požadovanou doménou a kritérii z Teiid UPDATE dotazu získat jména všech upravovaných položek (atribut itemName()). Teprve poté lze pomocí několika PutAttributes, či jediného BatchPutAttributes dané položky upravit.

5.5 DELETE

Podobně jako u příkazu UPDATE je nejprve potřeba získat jména všech položek, které mají být smazány a ty následně pomocí DeleteAttributes smazat z databáze.

6 Implementace

V této kapitole bude rozebrána konkrétní implementace, problémy, které se během implementace vyskytly, a jejich řešení.

6.1 Konektor

Základním kamenem a prvním krokem v implementaci bylo vytvoření konektoru.

Java EE Connector Architecture (JCA) je standardizované řešení pro připojení k podnikovým informačním systémům (enterprise information systems). Stejně jako je JDBC zodpovědné pro připojení Java EE aplikací k databázím, JCA je obecnější architektura pro připojení k systémům, pro které není vytvořen JDBC ovladač. Základem každého konektoru je tzv. resource adapter, jež je odpovědný za přístup a interakci s daným informačním systémem, který cheme připojit. Jednotlivé Java EE aplikace, nasazené v aplikačním serveru, poté tento resource adapter využívají pro komunikaci.

Specifikace JCA je vyvíjena v rámci Java Community Process pod číslem JSR 322^1

6.1.1 Modul simpledb-api

Tento modul reprezentuje API pro komunikaci s databází SimpleDB a jako samostatný modul vzniknul hlavně kvůli oddělení závislostí na java knihovnu pro komunikaci se SimpleDB (aws-java-sdk) od ostatních modulů.

Modul obsahuje pouze jedinou java třídu a jedno rozhraní a to SimpleDBAPIClas a SimpleDBConnection.

SimpleDBConnection je rozhraní rozšiřující rozhraní Connection
z balíčku javax.resource.cci (Connection reprezentuje připojení na externí zdroj na aplikační vrstvě – díky třídám implementující toto rozhraní je možné přistupovat k požadovaným
zdrojům).

^{1.} Dostupné na webu Java Community Process – http://www.jcp.org

• SimpleDBAPIClass je třída zaobalující potřebné příkazy databáze SimpleDB. Za povšimnutí stojí hlavně metoda Set<String> getAttributeNames(String domainName), která vrací jména všech atributů v doméně, ovšem jediný způsob jak toho docílit je provedení příkazu SELECT * FROM <domainName> a z odpovědi získat jména všech atributů (nestačí dotázat se například na jednu položku, nebot kdyby daná položka neměla vyplněný nějaký atribut, tento atribut by v odpovědi nebyl obsažen).

Také je v této třídě obsažena veškerá logika manipulace s vícehodnotovými atributy.

6.1.2 Modul connector-simpledb

Jedná se o plnohodnotný, ikdyž poměrně jednoduchý, Java EE konektor pro SimpleDB. Konektory jsou běžně baleny jako RAR (Resource Adapter Archive), které lze poté nasadit na aplikační server pouhým nakopírováním do složky deploy serveru. Teiid poskytuje základní implementaci rozhraní potřebných pro vytvoření zákadního konektoru. Zde bylo důležité uzpůsobit tuto základní implementaci potřebám databáze SimpleDB.

- Třída SimpleDBManagedConnectionFactory rozšiřuje abstraktní třídu BasicManagedConnectionFactory (základní Teiid implementace). V této třídě je nutno definovat proměnné, které jsou potřebné pro připojení ke zdroji tedy proměnné ve kterých bude uložen ID přístupového klíče a tajný přístupový klíč spolu s metodami pro jejich nastavení a získání (get a set metody). Požadované hodnoty budou aplikačním serverem získány z konfiguračního souboru serveru (typicky třeba standalone.xml) a vloženy pomocí set metod do těchto proměnných. Další důležitou částí je implementace abstraktní metody creteConnectionFactory(), pomocí které je vytvořena instance ConnectionFactory. Ta slouží ke generování jednotlivých připojení ke zdroji dat (SimpleDB).
- Jako implementace rozhraní Connection zde slouží třída SimpleDB ConnectionImpl. Ta kromě implementování rozhraní Connection rozšiřuje základní Teiid implementaci BasicConnection. Nám zde tedy stačí zajistit přístup k instanci třídy SimpleDBAPIClass. To

je splněno instanciováním v konstruktoru a přiřazením do privátní proměnné, která je poté dostupná pomocí její get metody.

S takto připraveným připojením lze poté v samotném překladači snadno volat metody definované v SimpleDBAPIClass např. takto:

• Dalším krokem je vytvoření konfiguračních souborů MANIFEST.MF a ra.xml. Oba soubory je nutno umístit do složky META-INF.

MANIFEST.MF obsahuje pouze závislosti resource adapteru. V případě našeho konkrétního adapteru je to:

```
Dependencies: org.jboss.teiid.common-core,
org.jboss.teiid.api,javax.api,
org.jboss.teiid.translator.simpledb.api
```

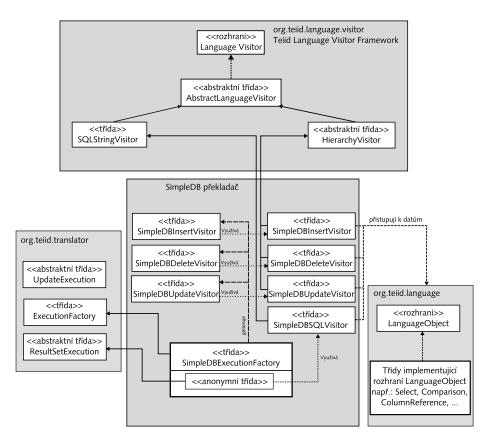
V deployment descriptoru ra.xml definujeme hlavní třídu resource adapteru (tj. třída implementující rozhraní Resource Adapter), třídu implementující rozhraní ManagedConnectionFactory a definujeme proměnné potřebné k připojení k SimpleDB (ID přístupového klíče a tajný klíč).

Celý tento modul je poté běžně zkompilován a balen jako Resource Adapter Archive – RAR (běžný Java archive – JAR s příponou .rar), který může být nasazen na aplikační server zkopírováním do složky deploy/. Jelikož se zde ale nejedná o konektor třetí strany, ale o konektor, který bude dodáván s projektem Teiid jako jeden ze základních konektorů, nestačí zajistit, že bude sestaven jako RAR, ale je potřeba, aby ve výsledku byl zařazen mezi moduly aplikačního serveru. K tomu potřebné kroky budou popsány níže v kapitole 6.3.1 zabývající se kompilováním a sestavováním projektu pomocí projektu Apache Maven.

6.2 Překladač

Tento modul je rozdělen na tři logicky oddělené části. V první je pouze třída SimpleDBExecutionFactory, která je základní třídou překladače. V další části jsou zde takzvané executory – třídy zajišťující vykonávání

jednotlivých příkazů. Jako poslední jsou takzvané visitory – třídy, které prochází strukturu Teiid SQL příkazu a získávají data, jež jsou poté použita v executorech. Každá z těchto částí je v samostatném java balíčku.



Obrázek 6.1: Struktura překladače SimpleDB

6.2.1 SimpleDBExecutionFactory

Základním kamenem SimpleDB překladače je třída SimpleDBExecution Factory rozšiřující abstraktní třídu ExecutionFactory<F,C>, kde F je factory třída konektoru a C je třída připojení – v našem případě se jedná o ConnectionFactory a SimpleDBConnection.

Nejprve v této třídě najdeme metody definující schopnosti překladače. Jedná se o metody s prefixem supports vracející boolean hodnotu podle toho zda překladač danou schopnost podporuje, či ne. Pro překladač SimpleDB byla zvolena tato množina podporovaných funkcí: supportsCompareCriteriaEquals supportsCompareCriteriaOrdered supportsInCriteria supportsIsNullCriteria supportsRowLimit supportsNotCriteria supportsOrCriteria supportsOrCriteria SupportsLikeCriteria Zbylé funkce obstarává logika Teiidu.

Dále tato třída obsahuje metodu void getMetadata(MetadataFactory metadataFactory, SimpleDBConnection conn) (ukázaná na obrázku 6.2.1), kterou Teiid volá při inicializaci pro každou uživatelem definovanou virtuální databázi. Úkolem této metody je načíst strukturu databáze (tabulky, sloupce, typy, ...) a pomocí metadataFactory ji předat Teiidu. Toho je docíleno iterací přes všechny domény a na nich voláním metody getAttributeNames() (metoda třídy SimpleDBAPIClass k jejíž instanci lze přistupovat přes třídu implementující připojení – SimpleDBConnection). Je nutné nastavit všem sloupcům datový typ String a také nezapomenout na atribut itemName(). Takto získané data poté stačí uložit do instance třídy MetadataFactory.

Poslední dvě implementované metody v této třídě jsou metody createResultSetExecution a createUpdateExecution, kde obě mají ve vstupních parametrech příkaz (SELECT, UPDATE, ...), kontext, metadata a připojení. Obě tyto metody vrací instanci třídy implementující rozhraní Execution. Z tohoto rozhraní je pro implementaci SimpleDB překladače nejdůležitější metoda void execute(), jejíž implementace je odpovědná za provádění konkrétního příkazu.

• createResultSetExecution

Tato metoda je zodpovědná za veškeré příkazy určené k získávání dat – tedy primárně příkaz SELECT. Metoda createResultSet Execution vrací nově vytvořenou anonymní třídu s implementovanými metodami void execute() a List<?> next(). Metoda execute pouze pomocí třídy SimpleDBSQLVisitor získá seznam sloupců, poté pomocí stejné třídy získá textový řetězec odpovídající příkazu SELECT a nad těmito daty zavolá metodu performSelect

```
public void getMetadata(MetadataFactory metadataFactory,
                            SimpleDBConnection conn){
     List<String> domains = conn.getAPIClass().getDomains();
     for (String domain : domains) {
       Table table = metadataFactory.addTable(domain);
       table.setSupportsUpdate(true);
       Column itemName = new Column();
       itemName.setName("itemName()");
       itemName.setUpdatable(true);
       itemName.setNullType(NullType.No_Nulls);
       Map<String, Datatype> datatypes = metadataFactory
11
                                           .getDataTypes();
12
       itemName.setDatatype(datatypes.get("String"));
13
       table.addColumn(itemName);
14
       for (String attrName : conn.getAPIClass()
15
                               .getAttributeNames(domain)) {
         Column column = new Column();
17
         column.setUpdatable(true);
         column.setName(attrName);
19
         column.setNullType(NullType.Nullable);
20
         column.setDatatype(datatypes.get("String"));
         table.addColumn(column);
       }
     }
24
   }
25
```

Obrázek 6.2: Ukázka metody getMetadata

API třídy, která získá data z databáze a vrátí je jako seznam. Ten je uložen do interní proměnne a v metodě next() jsou tyto data pomocí iterátoru předávána Teiidu.

• createUpdateExecution

Zde se obstarává vykonávaní všech metod manipulujících s daty – INSERT, UPDATE, DELETE a BatchedUpdate (který ovšem překladač simpledb nepodporuje).

Opět, podobně jako u createResultSetExecution je zde potřeba vrátit třídu implementující rozhraní UpdateExecution, které se

od ResultSetExecution liší pouze v metodě získávání dat. Místo List<?> next() je zde int[] getUpdateCounts().

6.2.2 Executory

Jelikož je v metodě createUpdateExecution situace složitější než v metodě createResultSetExecution a řešení pomocí anonymní třídy by bylo velmi rozsáhlé, byla zde implementace rozdělena do 3 samostatných tříd podle příkazu, který zpracovávají – SimpleDBInsertExecute, SimpleDBDeleteExecute a SimpleDBUpdateExecute.

Všechny tyto tři třídy využívají visitory (třídy vytvořené podle návrhového vzoru Visitor, budou popsány v kapitole 6.2.3) pro získání relevantních dat ze zadaného příkazu.

- SimpleDBInsertExecute je nejjednodušší z trojice executorů. Pouze pomocí SimpleDBInsertVisitor získá kolekci dvojic <jménoAtributu, hodnotaAtributu>, kde hodnota může být ve formátu ^\[.+\]\$, což značí vícehodnotový atribut. Tuto kolekci poté předá metodě perform Insert() API třídy. O správné zpracování vícehodnotových atributů se postará tato metoda.
- SimpleDBUpdateExecute je opět poměrně jednoduchá třída mezivrstva mezi visitorem a API třídou vykonávající samotný dotaz na SimpleDB. Pomocí visitoru zjistí, které položky odpovídají porovnání v dotazu. Přesněji řečeno získá hodnotu atributu itemName() všech položek odpovídajících podmínce WHERE. Dále zkonstruuje mapu map Map<String, Map<String, String> pro každý název položky získá pomocí visitoru SimpleDBUpdate Visitor mapu <jménoAtributu, hodnotaAtributu> a s touto mapou map provede pomocí metody performUpdate() API třídy samotné upravení dat v databázi.
- V případě SimpleDBDeleteExecute je zde pro jednoduchost a
 efektivnost rozděleno vykonávání do tří nezávislých větví podle
 situací, které mohou nastat:
 - Příkaz DELETE nemá klauzuli WHERE
 V tomto případě executor rovnou pomocí API třídy zjistí hodnoty atributu itemName() všech položek v dané doméně

a tyto položky postupně pomocí metody performDelete() API třídy vymaže.

- Příkaz DELETE má klauzuli WHERE ve formátu itemName() = <hodnota>

Zde se jedná o jednoduché vymazání jediné položky. Tato položka je pomocí metody performDelete() vymazána.

 Příkaz DELETE má klauzuli WHERE ve formátu jiném než itemName() = <hodnota>

V tomto případě je nutné nejprve zjistit hodnoty atributu itemName() položek, jež odpovídají podmínce klauzule WHERE. Tato logika je ponechána visitoru a zde se poté jen zavolá na získaných jménech metoda performDelete() API třídy.

Všechny tyto executory mají povinnost pamatovat si počet upravených, přidaných, či vymazaných řádků a tuto hodnotu zpřístupnit pomocí metody int[] getUpdateCounts()

6.2.3 Visitory

Tato sekce obsahuje 4 visitory. Každý ze 4 příkazů SELECT, UPDATE, DELETE, INSERT má jiné požadavky, proto pro každý z nich byl vytvořen samostatný visitor.

Nejprve je ale třeba vysvětlit návrhový vzor Visitor, na kterém je celá tato sekce postavená.

Návrhový vzor Visitor

Návrhový vzor visitor (někdy též návštěvník) je jedním ze základních návrhových vzorů popsaných již roku 1994 v knize Design Patterns: Elements of Reusable Object-Oriented Software. Jedná se o návrhový vzor, pomocí kterého je možné přidat skupině tříd dodatečnou funkcionalitu bez nutnosti změnit všechny tyto třídy. Také umožňuje funkcionalitu rozšířit za běhu programu.

V tomto návrhovém vzoru jsou třídy rozdělené do dvou skupin – navštěvované třídy a navštěvující třídy. Navštěvované třídy poskytují pouze základní funkcionalitu a navíc musí implementovat metodu, která příjme návštěvníka a předá mu data nutná k jeho správnému fungování.

Návštěvníci pro každou třídu, které chce rozšířit funkcionalitu, implementuje metodu visit se vstupním parametrem navštěvované třídy.

Jazykový visitor v Teiidu

Teiid disponuje rozhraním pro procházení a získávání dat ze stromů objektů jazyka založené na návrhovém vzoru visitor.

Každý Teiid příkaz je reprezentován stromem jazykových objektů – tříd implementujících rozhraní LanguageObject. Toto rozhraní definuje jedinou metodu:

```
void acceptVisitor(LanguageObjectVisitor visitor);
```

LanguageObjectVisitor je základní rozhraní pro všechny visitory a definuje visit metody pro všechny jazykové objekty jako například:

```
public void visit(AggregateFunction obj);
```

Teiid kromě základních rozhraní poskytuje i 3 základní implementace, kterých se dá využít při psaní vlastního visitoru:

- AbstractLanguageVisitor je prázdnou implementací rozhraní LanguageObjectVisitor poskytující nástroje pro procházení stromu jazykových objektů (sama ale žádné procházení nedělá). Tato třída není určena pro přímé použití, proto je definována jako abstraktní a je určena pouze pro použití jako rodičovská třída k rozšíření.
- HierarchyVisitor je podtřídou AbstractLanguageVisitor a je oproti její nadtřídě schopna projít všechny uzly stromu jazykových objektů. Nad těmito objekty ovšem neprovádí žádnou akci, pouze poskytuje jakýsi návod jak projít celý strom. Tato třída je také definována jako abstraktní a je určena k rozšiřování.
- DelegatingHierarchyVisitor je rozšířením HierarchyVisitor o možnost projít strom před a po projití hlavního visitoru. Tento nástroj není v případě SimpleDB nutné využívat, proto se jím nebudeme zabývat dále.
- SQLStringVisitor je rozšířením základní abstraktní třídy Abstract LanguageVisitor, která dokáže daný objekt Teiid jazyka převést na textový řetězec řetězec odpovídající SQL příkazu.

• CollectorVisitor je třída vhodná pro získání všech objektů určitého typu z jazykového stromu.

SimpleDBSQLVisitor

SimpleDBSQLVisitor není v této práci použit pouze pro příkaz SELECT, ale využívají jej i ostatní visitory pro získání jmen položek vyhovující podmínce.

Jelikož má SimpleDB příkaz SELECT mírně odlišnou strukturu a nějaké omezení, nelze použít Teiidem dodávaný SQLStringVisitor, ale byla vytvořena tato třída. SimpleDBSQLVisitor je rozšířením třídy SQLStringVisitor s přetíženýma metodama visit pro objekty Select, ColumnReference, Limit, Like a Comparison.

public void visit(Select obj)

Tato metoda je přetížena kvůli nutnosti odstranit atribut itemName() ze seznamu sloupců (itemName() je vracen automaticky a není třeba se na něj dotazovat)

- - 'tabulka'. 'sloupec', což pro SimpleDB není žádoucí a je potřeba vypisovat sloupec bez tabulky.
- public void visit(Comparison obj)

Jelikož Teiid podporuje operátor NOT (a v SimpleDBExecution Factory bylo definováno, že náš překladač operátor NOT pdporuje), zdálo by se, že v této oblasti je vše v pořádku. Není tomu ovšem tak, neboť ve chvíli, kdy překladač podporuje NOT operátor, zaručuje také podporu negovaných operátorů. Jedním z těchto negovaných operátorů je operátor "nerovná se -<>", a jelikož jej databáze SimpleDB nepodporuje, musí být při generování SQL řetězce převeden na "NOT ="

Další změny jsou pouze minoritního charakteru.

SimpleDBInsertVisitor

Vše co je potřeba na vykonání SimpleDB příkazu PutAttributes je jméno domény a mapa jména atributu a hodnot atributů. To je zajištěno rozšířením abstraktní třídy HierarchyVisitor a přetížením jeho visit metod pro parametry typu ColumnReference a ExpressionValueSource.

Při návštěvě ColumnReference (sloupců) se tvoří seznam názvů sloupců. Poté se při návštěvě ExpressionValueSource (ekvivalent klauzuli VALUES) tvoří mapa, kde jako klíč poslouží jméno atributu a jako hodnota hodnota atributu. Jelikož HierarchyVisitor prochází pomyslný strom Teiid příkazu do hloubky, je zajištěno, že seznam jmen atributů bude sestaven před začátkem zpracovávání vkládaných hodnot.

Pro získání těchto hodnot je implementována statická metoda get ColumnsValuesMap(Insert insert), ta instanciuje vlastní třídu předá ji objektu Insert jako návštěvníka, který ji projde. Následně vrátí získané hodnoty.

${\bf Simple DBUp date Visitor}$

Ikdyž je i tento visitor založen na HierarchyVisitor je zde situace poněkud složitější, než v případě SimpleDBInsertVisitor a to hlavně protože pokud v příkazu existuje podmínka, je nutné zjistit jména všech položek odpovídajících podmínce. Proto je zde zvolen jiný přístup, než u SimpleDBInsertVisitor (statické třídy pro získávání dat). Zde je navštěvování položek příkazu spuštěno v konstruktoru, tedy při vytvoření instance, a následně lze get metodami získat "vydolované" data.

Konstruktor je parametrický a kromě instance Update přijímá i instanci připojení a to z kvůli možné podmínce (je potom potřeba dotázat se databáze na jména položek vyhovující podmínce).

Požadované data zde jsou: název domény, mapa jmen atributů a jejich hodnot a seznam jmen položek odpovídajících podmínce.

 $\mbox{P{\sc r}{\sc et}}$ etížené metody visit jsou pro objekty typu $\mbox{Update},$ $\mbox{SetClause}$ a $\mbox{Comparison}$

• Update kromě implicitního zavolání metod visit pro objekty níže ve stromu příkazu (SetClause, Condition) si také uloží jméno

domény do privátní proměnné.

- SetClause vytvoří a naplní mapu jmen atributů a jejich hodnot.
- Hlavním úkolem metody visit(Comparison obj) je získání hodnot atributu itemName() všech položek vyhovující podmínce. To lze jednoduše zajistit SELECT dotazem přímo na databázi SimpleDB, kde se do WHERE klauzule vloží řetězec vygenerovaný pomocí SimpleDBSQLVisitoru pro danou podmínku, jak je vidět v následující ukázce kódu na řácích 4-6. Na řádcích 7-8 pak pouze probíhá uložení získaných jmen položek do privátní proměnné itemNames.

SimpleDBDeleteVisitor

Zde je použit stejný přístup jako u SimpleDBUpdateVisitor. Tedy spuštění procházení stromu v parametrickém konstruktoru, který kromě instance navštěvovaného objektu přijímá také API třídu SimpleDBAPIClass potřebnou pro komunikaci se SimpleDB.

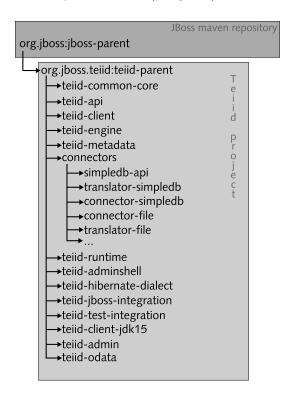
Je zde potřeba rozlišovat mezi třemi základními situacemi:

- Žádná WHERE klauzule tato situace je vyřešena již v executoru SimpleDBDeleteExecute dotázáním na existenci této klauzule a případným smazáním všech záznamů z domény.
- V klauzuli WHERE je jednoduchá podmínka tvaru itemName() = <hodnota> nebo <hodnota> = itemName(). V tomto případě je nastavena hodnota privátní proměnné boolean isSimpleDelete na true. Na tuto proměnnou se poté dotazuje SimpleDBDelete Execute a zařizuje se podle ní.

• Posledním případem je složitější podmínka ve WHERE klauzuli. V tomto případě se SimpleDBDeleteVisitor chová téměř totožně jako SimpleDBUpdateVisitor a to tak, že se nejprve dotáže databáze SimpleDB jednoduchým SELECT příkazem s WHERE klauzulí daného DELETE příkazu (vygenerovanou pomocí SimpleDBSQL Visitor).

6.3 Sestavení

Pro kompilaci a sestavení celého projektu je použit projekt Apache Maven. Maven kromě usnadnění a zautomatizování procesu sestavení také obstarává správu závislostí. Schopnosti mavenu je dále možné rozšířit pomocí zásuvných modulů (plug-inů).



Obrázek 6.3: Maven struktura projektu Teiid

Projekt Teiid je rozdělen do takzvaných modulů. Moduly jsou jednotlivé logické celky vytvořené jako java projekty. Každý takový modul

má svůj soubor pom.xml (Project Object Model) – konfigurační soubor projektu. V tomto souboru jsou definovány identifikátory projektu (ID artefaktu, ID skupiny, verze, ...), identifikátory rodičovského POM souboru, závislostí a konfigurací použítých maven zásuvných modulů.

6.3.1 Konfigurace jednotlivých SimpleDB modulů

• simpledb-api

Zde není potřeba žádné speciální konfigurace. Stačí definovat v pom.xml závislosti, rodičovské pom.xml a v rodičovském pom.xml definovat tento projekt jako modul (přidat do tagu <modules>).

• connector-simpledb

Tento modul má na konfiguraci zvláštní požadavky, neboť musí být sestaven jako rar archiv a následně nainstalován do lokálního repozitáře, aby pak byl dostupný v poslední fázi sestavení kompletního projektu Teiid.

Potřebné soubory MANIFEST.MF a ra.xml byly popsány již v kapitole 6.1.2, zbývá tedy nastavit Maven pomocí pom.xml. K sestavení projektu jako rar je použit zásuvný modul maven-rar-plugin spuštěný v rámci maven fáze install. Toto vytvoří korektní rar archiv a následně (stále ve fázi install) je pomocí zásuvného modulu maven-install-plugin tento soubor nainstalován do lokálního maven repozitáře, aby byl přístupný i ostatním projektům.

• translator-simpledb

Překladač nevyžaduje žádné speciální nastavení. Stačilo tedy zajistit, aby v souboru pom.xml byl definován správný rodič (org.jboss.teiid:connectors) a v rodiči byl projekt translator-simpledb registrován jako modul.

6.3.2 Nastavení zásuvného modulu maven assembly plugin

Projekt Teiid je dodáván v distribucích Teiid Runtime nebo Teiid Embedded. Další dodávané produkty jsou JDBC ovladač a Teiid Admin Shell.

Teiid Runtime je Teiid připravený k okamžitému nasazení na aplikační server WildFly (verze 8 a vyšší), nebo Red Hat JBoss Enterprise Application Platform (verze 6.1 a vyšší). Obsahuje v sobě kromě zkompilovaných knihoven, modulů a dokumentace také výchozí konfigurační soubory včetně standalone.xml.

Teiid Embedded je odlehčená verze Teiidu pro použití bez aplikačního serveru, schopna běžet jako samostatná java aplikace. Tímto bohužel přichází o vlastnosti jako například autentizace, přístup přes administrační rozhraní nebo správu připojení (connection pooling).

Sestavení těchto distribucí ze zkompilovaných artefaktů do finálních .zip souborů má na starosti Maven Assembly Plugin.

Z pohledu SimpleDB konektoru a překladače bylo potřeba zajistit 3 věci:

- Upravit kostru konfiguračního souboru aplikačního serveru. To znamená přidat do souboru standalone-teiid.xml definici resource adapteru konektoru SimpleDB a zajistit, aby překladač byl uveden v subsystému teiidu.
- Vytvořit konfigurační soubory modulů (module descriptor) pro každý modul překladače simpledb (api, konektor, překladač)
- Upravit konfigurační soubor, podle kterého zásuvný modul maven assembly zkompletuje výsledné .zip soubory. Níže je výňatek z tohoto konfiguačního souboru (tzv. assembly descriptor). V tomto konkrétním případě se jedná o instalaci artefaktu simpledb-api jako modulu aplikačního serveru JBoss AS (jak je vidět na řádcích 21-22):

6. Implementace

```
<dependencySet>
12
                  <useProjectArtifact>true</useProjectArtifact>
13
                  <unpack>false</unpack>
14
                  <useTransitiveDependencies>
                    false
16
                  </useTransitiveDependencies>
17
                  <useDefaultExcludes>true</useDefaultExcludes>
18
              </dependencySet>
19
         </dependencySets>
       <outputDirectory>modules/system/layers/base/org/jboss/
^{21}
                  teiid/translator/simpledb/api/main</outputDirectory>
22
       <fileMode>0644</fileMode>
23
     </binaries>
24
   </moduleSet>
   . . .
```

7 Quickstart

Jelikož se SimpleDB profiluje jako velmi rychlá, velmi dobře škálovatelná databáze s omezeními co se týče struktury, velikosti dat a konzistence, je její nasazení vhodné v prostředích:

- Kde je poměr čtení-zápis výrazně ve prospěch čtení čte se často a je požadována rychlost odpovědi, zapisuje se zřídka (kvůli konzistenci)
- Kde je kladen vysoký důraz na rychlost čtení i na úkor konzistence (přístup "nevadí, že nedostanu aktuální výsledek, hlavně když jej dostanu rychle")

Běžný přístup ve firemním prostředí je nasazení SimpleDB jako doplňkové databáze ke klasické relační databázi. V této situaci mohou být v SimpleDB uložena například metadata, případně často čtené položky.

Inspirací pro zdrojová data pro tutoriál byla firma Netflix. Netflix je firma živící se převážně streamováním filmů a seriálů a pro správu dat zvolil řešení firmy Amazon. Mezi jinými tedy i databázi SimpleDB¹.

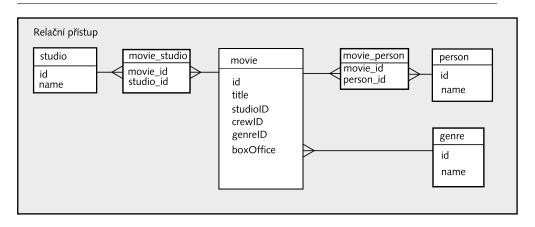
V rámci této diplomové práce byl jako zdroj dat zvolen .csv soubor s daty o filmech vydaných v lednu roku 2013. Soubor obsahuje:

- Název filmu
- Studio ve kterém byl film natočen (může se jednat o více studií)
- Režisér a herecké obsazení (zde se jedná o čárkami oddělené jména)
- Žánr filmu (žánrů může být více)
- Box office, aneb kolik dolarů daný film vydělal.

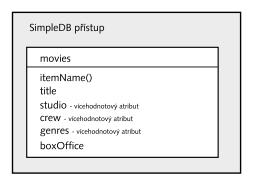
Na obrázku 7.1 je znázorněno, jakou strukturu by měla klasická relační databáze pro výše zmíněné data.

Na druhou stranu obrázek 7.2 ukazuje jak by s velkou pravděpodobností byla uložena data v databázi SimpleDB. Normalizace databáze zde nehraje roli, duplikáty nejsou na škodu. Je zde kladen důraz na jednoduchost a rychlost.

^{1.} http://techblog.netflix.com/search/label/SimpleDB

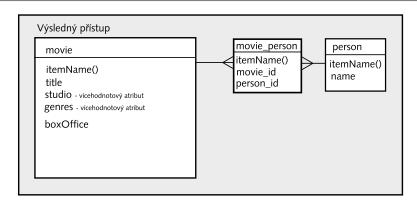


Obrázek 7.1: Struktura uložení dat v relační databázi



Obrázek 7.2: Struktura uložení dat v databázi SimpleDB

Aby byly ukázány aspekty obou přístupů – jak relačního, tak přístupu z pohledu SimpleDB – jsou vzorová data uloženy v databázi se strukturou ukázanou na obrázku 7.3. Takto bude možnost demonstrovat například schopnost spojování výsledků ze dvou a více vstupních množin (klauzule JOIN – jedna ze základních schpností relačních databází, která databáze SimpleDB nepodporuje), nebo schopnost pracovat s vícehodnotovými atributy (což je výsadou databáze SimpleDB oproti relačním databázím).



Obrázek 7.3: Výsledná (kompromisní) struktura databáze

V rámci přípravy tutoriálu byl vytvořen java program impotData, který dokáže umístit vzorové data do uživatelovy instance databáze SimpleDB. Pro snadné použití byl projekt mavenizován a pro snadnou dostupnost byl spolu s tutoriálem umístěn na server GitHub, který je určen k hostování a verzování projektů pomoví verzovacího systému Git.

Do stejného repozitáře byl také umístěn soubor README.md (formátovaný pomocí Markdown) obsahující vlastní tutoriál, který uživatele provede (v anglickém jazyce) nainstalováním Teiidu, vytvořením virtuální databáze, připojením k lokálně běžící instanci Teiidu a několika vzorovými dotazy na SimpleDB pomocí JDBC ovladače Teiidu.

Příloha A je pouze tutoriál převedený z Markdown do latexu. Originální Markdown soubor je v GitHub repozitáři, nebo na přiloženém CD.

8 Závěr

Výsledkem práce je funkční konektor (resource adapter) pro připojení k SimpleDB. Dále byl vytvořen modul Teiid překladače (translator) pro SimpleDB ve kterém se povedlo zvládnout problematiku mapování Teiid SQL dotazů na dotazy databáze SimpleDB. Také zde byl úspěšně řešen problém multihodnotových atributů databáze SimpleDB. Tyto části dohromady tvoří funkční modul projektu Teiid a již byly zařazeny do hlavní vývojové větve projektu. Teiid 8.7 již v sobě bude obsahovat modul pro komunikaci s databází SimpleDB vytvořený v rámci této práce.

Druhým výstupem je tutoriál v anglickém jazyce, hostovaný veřejně na serveru GitHub, který slouží jako uvedení do problematiky pro nové uživatele a demonstruje schopnosti vyvinutého Teiid modulu.

Tato práce pro mě znamenala jedny z prvních krůčků do světa open-source a velkou zkušeností pro mě byla spolupráce s lidmi, kteří programují otevřený software, jelikož bych se otevřeným softwarem rád zabýval i v budoucnu.

Dalším krokem ve vývoji Teiid modulu pro komunikaci se SimpleDB by bylo zaměření se na výkon – sepsání "performance testů" a optimalizace kódu. Také je možnost pokusit se začlenit tutoriál vyvinutý v rámci této práce mezi oficiální "quickstarty"¹.

 $^{1. \ \} https://github.com/teiid/teiid-quick starts$

Literatura

- [1] Design patterns: elements of reusable object-oriented software. Addison-Wesley, Massachusetts, c1995. 395 s., ISBN: 02-016-3361-2.
- [2] Amazon. Amazon simpled b developer guide. http://awsdocs.s3.amazonaws.com/SDB/latest/sdb-dg.pdf. [cit. 2014-08-01].
- [3] James A. Larson Amit P. Seth. Federated database systems for managing distributed, heterogeneous, and autonomous databases. dostupné na http://knoesis.wright.edu/library/download/SL90.pdf. [cit. 2014-26-04].
- [4] Teiid developers. Teiid developer's guide. https://docs.jboss.org/author/display/teiid86final/Developer's+Guide. [cit. 2014-08-01].
- [5] The Apache Software Foundation. Maven assembly plugin documentation. dostupné na http://maven.apache.org/plugins/maven-assembly-plugin/. [cit. 2014-08-01].
- [6] Arun Gupta. Java EE 7 Essentials. O'Reilly Media, Sebastopol, 1 edition, 2013. ISBN: 978-1449370176.
- [7] Yury Izrailevsky. Nosql at netflix. http://techblog.netflix.com/2011/01/nosql-at-netflix.html. [cit. 2014-08-01].
- [8] Sun Microsystems. Java ee connector architecture specification. dostupné na http://download.oracle.com/otndocs/jcp/connector_architecture-1.6-fr-eval-oth-JSpec/. [cit. 2014-08-01].
- [9] James Murty. Programming Amazon Web Services: S3, EC2, SQS, FPS, and SimpleDB. O'Reilly, Sebastopol, c2008. 582 s. ISBN: 05-965-1581-2.
- [10] Margaret Rouse. Exploring data virtualization tools and technologies. dostupné na http://searchdatamanagement.techtarget.com/definition/data-virtualization. [cit. 2014-26-04].

- [11] John Ferguson Smart. Java Power Tools. O'Reilly, Sebastopol, c2009. ISBN: 978-0-596-52793-8.
- [12] Sonatype. Maven: the definitive guide. O'Reilly, Sebastopol, 1 edition, c2008. 452 s., ISBN: 978-0-596-51733-5.
- [13] Guarav Vaish. Nosql starter. Packt Publishing Limited, 1 edition, 2013. ISBN: 978-1849694988.

A Tutoriál

This is quickstart for SimpleDB connector and translator for Teiid - https://github.com/teiid/teiid

System Requirements

To run this quickstart with the provided build scripts, you need the following:

- 1. Java 1.6 or better, to run JBoss AS and Maven. You can choose from the following:
 - OpenJDK
 - Oracle Java SE
 - Oracle JRockit
- 2. Maven 3.0.0 or newer, to build and deploy the example
 - If you have not yet installed Maven, see the Maven Getting Started¹ Guide for details.
 - If you have installed Maven, you can check the version by typing the following in a command line:

mvn -version

- 3. The JBoss Enterprise Application Platform (EAP) 6.1 (and higher) distribution ZIP or the JBoss AS 7.2 (or WildFly 8 or higher) distribution ZIP.
 - For information on how to install and run JBoss, refer to the server documentation.
- 4. Amazon AWS credentials
 - If you don't have one, go to aws.amazon.com and sing up for using Amazon SimpleDB

 $^{1. \ \} http://maven.apache.org/guides/getting-started/index.html$

- Your access credentials can be found on https://portal.aws .amazon.com/gp/aws/securityCredentials
- 5. Client for executing queries against Teiid
 - Some JDBC client. This is preferred variant. This example will be demonstrated using Squirrel SQL client - http://squirrelsql.sourceforge.net/
 - Some tool for executing querries directly to Teiid. For example simpleclient from teiid-quickstarts github repository https://github.com/teiid/teiid-quickstarts

Installing Teiid

Project Teiid (version 8.6) is compatible with EAP 6.1 or WildFly 8².

- 1. Install application server (by uncompressing it to desired folder)
- 2. Download latest Teiid Runtime from http://www.jboss.org/teiid/downloads and install it
 - Installing teiid is just matter of extracting into WildFly or EAP directory.
- 3. Add connection definition to resource adapter
 - Open \$AS_ROOT_DIRECTORY/standalone/configuration/ standalone-teiid.xml in your favourite text editor
 - Add this snippet under simpled bresource adapter to look like so (do not forget to fill your access key id & access key):

^{2.} As SimpleDB support will be in Teiid since version 8.7 (and 8.7 is not out yet) you may need to compile teiid from source code as described in here: https://community.jboss.org/wiki/TeiidEclipseDevEnvironmentSetUpAndBuildingRuntimeArtifacts

- Create virtual database file (VDB) and deploy it:
 - Create file my-vdb.vdb with content:

 Save this file to your AS deploy folder (\$AS_ROOT_DIRECTORY/ standalone/deployments/my-vdb.vdb)

Prepare sample data in your SimpleDB database

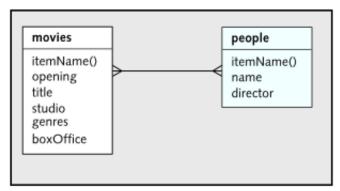
- 1. Clone git repository https://github.com/rhopp/teiidSimpleDBQuickstart
- 2. In root folder (the one with pom.xml in it) run

```
mvn verify -DkeyID=<yourKeyID> -DsecretKey=<yourSecretKey>
```

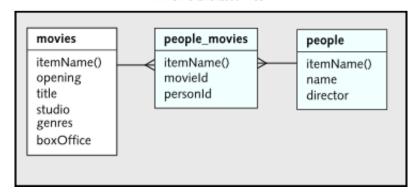
This should create 3 domains in you SimpleDB Database

- movies database of movies
- people database of actors and directors

• people_movies intersection table for m to n relationship between movies and people:

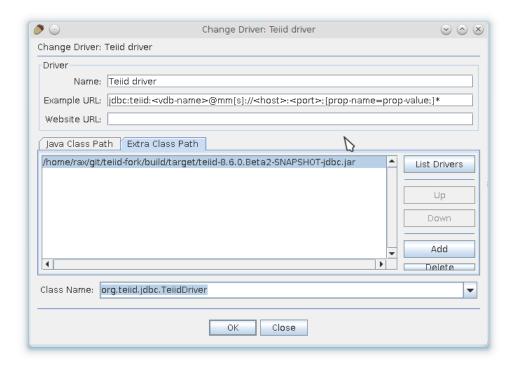


Which translates into:



Running the example

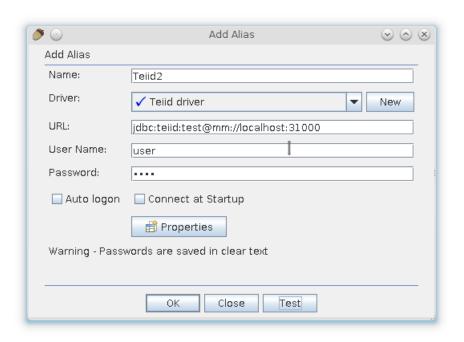
- (a) Install Squirrel SQL client
- (b) Download and install Teiid JDBC driver into Squirrel SQL client
 - Download Teiid JDBC driver from http://www.jboss.org/teiid/downloads
 - Create new driver in Squirrel SQL Client
 - Add Teiid JDBC Driver jar into Extra class path
 - As class name put org.teiid.jdbc.TeiidDriver as shown on figure A.1
- (c) Start Teiid



Obrázek A.1: New driver settings

- Start your application server like bin/standalone.sh -c standalone-teiid.xml
- If everything went right, something like TEIID40003 VDB Test.1 is set to ACTIVE should appear in application server log. This means, that virtual database is successfully deployed, connection to SimpleDB was successful and all metadata were loaded.
- (d) Connect Squirrell SQL client to running Teiid
 - Create new alias in Squirrel SQL Client
 - As driver choose Teiid driver, created in step 2.
 - URL is jdbc:teiid:test@mm://localhost:31000
 - Default values for username and password are user, user

- Everything should look like on figure A.2. Now you can test the connection and save it.



Obrázek A.2: New alias settings

- (e) Now you can try to execute SQL queries like:
 - SELECT * FROM people WHERE director=true for list of all directors
 - or

```
SELECT movies.title FROM movies

INNER JOIN people_movies

ON movies."itemName()"=people_movies.movieId

INNER JOIN people

ON people_movies.personId=people."itemName()"

WHERE people.name='Emma Stone'
```

for movie titles where Emma Stone was involved.

• Let's try to add some movie:

Note here, that the second value will be stored as multivalued attribute. Format for working with multivalue attributes is semicolon separated values enclosed in brackets

- Oh... Typo in movie title! Let's change that!

 UPDATE movies SET "title"='My movie'

 WHERE "itemName()"='00021'
- Want to delete movie from domain? No problem:

 DELETE FROM movies WHERE "itemName()"='00021'

B Obsah přiloženého CD disku

- Složka teiid-fork s kompletními zdrojovými kódy projektu Teiid obsahující již změny provedené v rámci této práce.
- Soubor teiidDiff soubor obsahující všechny změny provedené v rámci této práce (výstup příkazu git diff)
- Složka importData obsahující v sobě zdrojová data, projekt pro import dat do SimpleDB a soubor README.md, ve kterém je obsažen tutoriál