### Masarykova univerzita Fakulta informatiky



# Relační přístup k Amazon SimpleDB

DIPLOMOVÁ PRÁCE

Radim Hopp

### Prohlášení

Prohlašuji, že tato diplomová práce je mým původním autorským dílem, které jsem vypracoval samostatně. Všechny zdroje, prameny a literaturu, které jsem při vypracování používal nebo z nich čerpal, v práci řádně cituji s uvedením úplného odkazu na příslušný zdroj.

Radim Hopp

Vedoucí práce: Mgr. Marek Grác

### Poděkování

Rád bych poděkoval vedoucímu práce Mgr. Marku Grácovi za ochotný přístup a věnovaný čas, panu Lukáši Tinklovi a lidem z komunity KDE na IRC kanále #kde-devel za cenné rady.

# Shrnutí

Cílem této práce bylo důkladné prozkoumání stavu Kiosk Frameworku v KDE 4.x, zjištění stavu nástroje kiosktool v KDE 4.x a doplnění jeho funkčnosti.

## Klíčová slova

KDE, Kiosk Framework, kiosktool, Qt

# Obsah

1	Úvod
2	JBoss Teiid
	2.1 Části JBoss Teiid
3	Amazon SimpleDB
	3.1 Struktura databáze SimpleDB
	3.2 Vlastnosti databáze Amazon SimpleDB
4	Komunikace s databází Amazon SimpleDB
5	Mapování Teiid dotazů na SimpleDB dotazy 1
6	<b>Kód</b>
7	Tutoriál
8	<b>Závěr</b>

### 1 Úvod

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Donec blandit turpis sit amet nibh volutpat ultrices. Quisque ut placerat quam. Nunc pharetra non metus in vestibulum. In in leo porta, rutrum nisi a, scelerisque dolor. Donec non vehicula dui. Ut ut urna quis massa sollicitudin laoreet sed et sapien. Quisque pellentesque massa quam, vitae vulputate enim venenatis id. Curabitur ornare enim leo, et venenatis orci interdum id. Vivamus nunc augue, dictum eu semper consequat, vestibulum vitae eros. Phasellus sodales tincidunt odio, vel rhoncus orci dignissim eu.

Curabitur urna purus, varius id mattis adipiscing, aliquam et sem. Duis sed enim non nisl commodo molestie. Vestibulum gravida suscipit lectus vitae interdum. Maecenas quis vestibulum nibh. Nunc vel porta massa. Sed interdum tortor ac elit sollicitudin, ut auctor nisi ullamcorper. Integer nec eros tempus arcu convallis molestie consectetur ac nunc.

Pellentesque non posuere quam, et ultricies odio. Phasellus varius arcu ac arcu elementum venenatis. Aliquam tempor elit et urna suscipit facilisis. Quisque id ligula nec justo malesuada egestas vel eget nulla. Phasellus non bibendum sem. Ut venenatis quam id nibh cursus, ac convallis metus adipiscing. Integer imperdiet, lorem et ullamcorper pellentesque, ligula mi auctor elit, ut suscipit purus lorem in nibh. Ut aliquam nibh non adipiscing dignissim. Duis consectetur dui ac turpis semper, non lacinia metus feugiat. Aliquam malesuada congue felis eu luctus.

Nam id volutpat metus, vitae sodales enim. Nullam tempor odio libero, id iaculis magna pellentesque accumsan. Vestibulum accumsan mauris quis urna sodales, placerat imperdiet metus tincidunt. Nullam consequat purus sit amet purus consectetur porttitor. Praesent fringilla vitae turpis rutrum rhoncus. Aenean tincidunt, mauris in mattis ornare, dui elit lobortis enim, et elementum libero nulla ut sapien. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos himenaeos. Suspendisse commodo leo placerat rhoncus adipiscing. Etiam rhoncus rhoncus interdum. Sed sed nibh ut sapien varius sodales. Maecenas lacinia nunc eu neque tempus aliquet.

Vestibulum tempus laoreet lectus. Mauris accumsan velit ac erat condimentum pellentesque. Suspendisse et lorem vitae lorem volutpat interdum. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Sed ac tincidunt leo, sed vulputate mi. Maecenas et nulla egestas, adipiscing neque a, blandit massa. Nam ullamcorper, tortor id accumsan consectetur, tortor neque ultrices mi, a laoreet odio ipsum et tellus. Duis lobortis faucibus luctus.

#### 2 JBoss Teiid

JBoss Teiid je otevřený software pro virtualizaci dat z více zdrojů. Tento projekt je zaštitován v rámci JBoss komunitních projektů spolu s projekty jako WildFly nebo GateIn<sup>2</sup>.

Firma Red Hat nabízí také plně podporovanou a certifikovanou verzi pod názvem Red Hat JBoss Enterprise Data Services Platform. Tento produkt kromě projektu Teiid v sobě obsahuje také JBoss Enterprise Application Platform a další produkty $^3$ 

#### 2.1 Části JBoss Teiid

#### • Query engine

Jedná se o srdce projektu, které zpracovává relační, XML, XQuery a jiné dotazy ze zdrojů dat. Také zajišťuje podporu pro schémata vytvořené z jednoho, či z více různých zdrojů dat. V neposlední řadě se query engine stará o transakce a uživatelem definované funkce.

#### • JDBC ovladač

JDBC ovladač slouží pro jednoduché použití Teiidu v ostatních java aplikacích.

#### • Server

Tato část je zodpovědná za běh query enginu v rámci aplikačního serveru (WildFly nebo Red Hat JBoss Enterprise Application Platform) a zaručuje škálovatelnost a snadnou správu. Součástí je administrační konzole, ve které je možno jednoduše nastavit například deploynutou virtuální databázi nebo nastavení vláken query enginu.

#### Konektory

Teiid přichází s řadou konektorů, díky kterým je schopen napojit se na řadu různých zdrojů dat. Základním kamenem jsou konektory pro většinu relačních databází, webové služby, textových souborů a LDAP<sup>4</sup>.

<sup>1.</sup> http://www.jboss.org/overview/

<sup>2.</sup> kompletní seznam projektů na http://www.jboss.org/projects

<sup>3.</sup> kompletní seznam produktů a projektů obsažených v Red Hat JBoss Enterprise Data Services Platform i s použitými verzemi k naleznutí na https://access.redhat.com/site/articles/112333

<sup>4.</sup> Lightweight Directory Access Protocol)

Cíl této diplomové práce je rozšířit tuto sekci o connector pro NoSQL databázi Amazon SimpleDB.

#### Nástroje

#### Teiid Designer

Teiid Designer je separátní projekt (není součástí projektu JBoss Teiid), který ovšem také patří mezi komunitní projekty jboss.org. Jedná se o sadu zásuvných modulů pro vývojové prostředí Eclipse, které usnadní definování virtuálních databází (pohledy, procedury, ...)

#### Nástroje pro monitorování a správu

Dvěmi hlavními nástroji pro monitorování a správu jsou Teiid Web Console (V zásadě jde o rozšíření webové konzole aplikačního serveru o položky pro správu a monitorování Teiid instance) a zásuvný modul pro  $\mathrm{RHQ}^5$  pro kontrolu více serverů či clusterů Teiidu.

#### Skriptování

V rámci Teiidu je také distribuován Teiid AdminShell, což je skriptovací nástroj založený na jazyku Groovy. AdminShell umožňuje spravovat Teiid z příkazové řádky či pomocí skriptu, což uživateli velmi usnadní provádění často se opakujících činností.

<sup>5.</sup> RQH je komunitní projekt vedený pod jboss.org pro správu více serverů, http://www.jboss.org/rhq

### 3 Amazon SimpleDB

SimpleDB je databáze z dílen firmy Amazon a patří do skupiny produktů Amazon Web Services. Tato databáze je takzvaná NoSQL, což znamená, že data v ní jsou uložená ve formátu, jaký není běžný pro relační databáze (tabulky, sloupce, řádky). SimpleDB je poskytována firmou Amazon jako služba. To znamená, že není možné nasadit si databázi SimpleDB na vlastním serveru, ale běží pouze na serverech firmy Amazon.

#### 3.1 Struktura databáze SimpleDB

Struktura SimpleDB databází je možno přirovnat k tabulkovému procesoru.

#### • Uživatelský účet (Customer Account)

V rámci jednoho účtu lze mít více domén stejně jako v rámci jednoho souboru tabulkového procesoru je možno mít více listů s tabulkami.

#### • Doména (Domain)

Analogie k jedné tabulce v tabulkovém procesoru. Obsahuje řádky (položky), sloupce (atributy) a jednotlivé buňky (hodnoty).

#### Položky (Items)

Řádky tabulky. Reprezentují jednotlivé objekty uložené v databázi s jedním, či více vyplněnými atributy.

#### • Atributy (Attributes)

Sloupce tabulky. Určují kategorie dat, jakých můžou položky nabývat.

#### • Hodnoty (Values)

Hodnoty si lze představit jako jednotlivé buňky tabulky. Tady se ovšem analogie s tabulkovým procesorem rozchází, neboť jedna "buňka" může nabývat více hodnot najednou.

Navíc má každý prvek domény (řádek tabulky) povinný atribut ItemName, který musí být v dané doméně unikátní.

SimpleDB nepoužívá žádné jiné datové typy krome typu String, takže i čísla jsou v databázi uloženy a je s nimi nakládáno jako s textovými řetězci. To s sebou nese řadu problémů a hlavně zátěž na vývojáře aplikace tyto problémy řešit. Typickým příkladem takového problému je, že čísla nejdou řadit lexikograficky (lexikograficky: 10<2, což je špatně). Řešením je doplnění nul před čísla (00010>00002, což je správně).

#### 3.2 Vlastnosti databáze Amazon SimpleDB

#### SimpleDB jako služba

Databáze Amazon SimpleDB je dodávaná jako služba. To znamená, že Amazon neposkytuje možnost nasadit tuto databázi ve vlastním prostředí, ale provozuje ji pouze na svých serverech. Uživatel databáze se tedy nemusí starat o nastavování ani o hardware, ale například ani o škálování, nebo o replikaci dat, jelikož Amazon automaticky distribuuje a synchronizuje data v několika datových centrech umístěných v různých geografických zónách, čímž omezuje nejen riziko ztráty dat, ale také zvyšuje rychlost přístupu k datům v různých místech na světě. Tím pádem se může uživatel databáze plně zaměřit na práci s vlastními daty.

#### Flexibilita

Flexibilita je další výhoda databáze Amazon SimpleDB. Jelikož je to NoSQL databáze není potřeba mít pevně dané schéma, jak tomu bývá u SQL databází, ale nové atributy a entity mohou být přidávány takzvaně za pochodu.

#### Indexování

SimpleDB automaticky indexuje veškeré data v ní uložené, čímž tato povinnost odpadá z beder vývojářů aplikace a zvyšuje rychlost navracení výsledků čtecích operací.

#### Konzistence

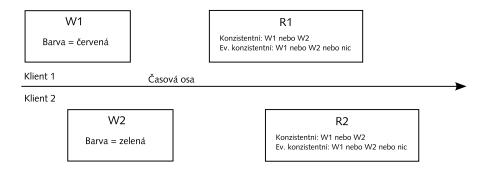
Amazon pro zápis zaručuje konzistenci takovou, že úspěšně provedený zápis (použitím příkazů jako např. PutAttributes, BatchPutAttributes, CreateDomain, . . .) znamená, že všechny kopie databáze byly změněny. Toto pojetí konzistence ovšem nezaručuje chování při překrytí dvou či více zápisů najednou. Pouze zaručuje, že výsledné data budou na všech kopiích databáze rovná hodnotě jednoho z těchto zápisů (toho, který databáze obdržela nejpozději). toto bude níže ilustrováno na příkladě. Při čtení si uživatel může zvolit mezi konzistentním a eventuálně konzistentním čtením. Konzistentní čtení zaručuje, že vrátí hodnotu po provedení posledního dosud přijatého zápisu. Eventuálně konzistentní čtení na druhou stranu vrátí hodnotu, která je aktuálně uloená na dotazovaném serveru (tj. může vrátit již neplatnou hodnotu).

#### Příklad konzistence

Na obrázku 3.1 je uveden příklad, kdy se překrývají dva zápisy. V této situaci není možné určit, jestli pro provedení obou zápisů bude výsledná hodnota atributu Barva rovna červená, nebo zelená z toho důvodu, že není zaručeno, kterou instrukci zpracuje SimpleDB jako první. Například kvůli vysoké latenci sítě prvního klienta bude nejprve přijata a zpracována instrukce W2 druhého klienta a následně přepsána instrukcí W1, tedy veškeré následné konzistentní čtení vrátí Barva=červená.

Jak bylo ukázáno, konzistentní čtení v tomto případě mohlo vrátit jak výsledek W1, tak výsledek W2. Oproti tomu, výsledek eventuálně konzitentního čtení může být kromě W1 či W2 také nic. Pravděpodobnost prázdného výsledku se s časem minimalizuje, neboli čím déle po zápisu je čteno, tím větší je pravděpodobnost korektního výsledku.

Obrázek 3.1: Ilustrace chování databáze SimpleDB



Základní rozdíl mezi konzistentním a eventuálně konzistentním čtením lze shrnout do tabulky:

Obrázek 3.2: Tabulka vlastností konzistentního a ev. konzistentního čtení

Eventuálně konzistentní čtení	í   Konzistentní čtení
Možné nekorektní výsledky	Vždy korektní výsledek
Rychlejší odezva	Možná pomalejší odezva
Větší dataová propustnost	Možná menší datová prostupnost

#### Omezení databáze SimpleDB

Kromě výše zmíněného chování, které by se v jistých situacích dalo považovat za omezení, je asi největším omezením velikost domény, jak co se místa na disku týče, tak také maximální počet atributů. Konkrétně je horní hranice 10 GB pro data a 1 miliarda atributů na jednu doménu. Domén je možno vytvořit až 250 na jeden uživatelský účet.

### 4 Komunikace s databází Amazon SimpleDB

#### Přehled příkazů SimpleDB

- CreateDomain slouží k vytvoření nové domény.
- **DeleteDomain** vymaže danou doménu.
- **ListDomains** vrátí seznam domén asociovaných s daným uživatelským účtem.
- **DomainMetadata** slouží k získání informací o dané doméně (datum vytvoření, počet položek v doméně, počet atributů, ...)
- **PutAttributes** vloží novou položku s danými hotnotami atributů, či upraví již stávající položku.
- Select se podobá běžnému SELECT příkazu, který je dobře známý z SQL jazyků. Je ovšem mírně omezen a to například absencí JOIN klauzule. Přesný přehled možností příkazu SELECT databáze SimpleDB je uveden v dokumentaci<sup>1</sup>
- **GetAttributes** vrátí hodnoty požadovaných atributů jedné dané položky. Umožňuje specifikovat jeden, či více požadovaných atributů, nebo také všechny atributy dané položky.

Prace s daty Unikatni ItemName Automaticke indexovani conditional put prace s cisly Vsechno string!

<sup>1.</sup> http://awsdocs.s3.amazonaws.com/SDB/latest/sdb-dg.pdf

5 Mapování Teiid dotazů na SimpleDB dotazy

# 6 Kód

# 7 Tutoriál

# 8 Závěr

# Literatura